

UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería



**Interfaz Biomédica para el Control de Sistemas Robóticos
Utilizando Señales EEG**

Trabajo de graduación presentado por Rodrigo Ralda González para
optar al grado académico de Licenciado en Ingeniería Mecatrónica

Guatemala,

2020

UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería



**Interfaz Biomédica para el Control de Sistemas Robóticos
Utilizando Señales EEG**

Trabajo de graduación presentado por Rodrigo Ralda González para
optar al grado académico de Licenciado en Ingeniería Mecatrónica

Guatemala,

2020

Vo.Bo.:

(f) _____
Dr. Luis Rivera

Tribunal Examinador:

(f) _____
Dr. Luis Rivera

(f) _____
MSc. Carlos Esquit

(f) _____
MSc. Miguel Zea

Fecha de aprobación: Guatemala, 5 de diciembre de 2020.

Esta investigación surgió de la oportunidad de pertenecer a la línea de investigación biomédica de la universidad y mi interés por controlar dispositivos robóticos a partir de señales cerebrales. A medida que la tecnología ha estado avanzando, también lo han hecho los proyectos inclusivos que buscan reinsertar a personas con algún tipo de discapacidad a la sociedad. Este es el caso de este proyecto, que espera generar interés en futuras generaciones para aplicar las interfaces cerebro computador en prótesis, equipo de rehabilitación o equipo industrial.

Culminar este trabajo de graduación no hubiera sido posible sin el apoyo de varios. Primero que todo agradecer a Dios por haberme guiado, apoyado y darme fortaleza en los momentos difíciles. Quiero agradecer a mis padres César y Michelle, hermano Javier, abuelos y familia en general por creer en mí desde el principio y siempre apoyarme incondicionalmente con amor. También agradecer a mis amigos y compañeros de estudios y felicitarlos por haber culminado este logro tan importante en nuestro desarrollo profesional. Por último, agradecer a la Universidad del Valle de Guatemala y al grupo de profesionales que contribuyeron con el desarrollo de mi carrera, especialmente al Dr. Luis Rivera por su dedicación y paciencia en compartirme sus conocimientos y guiarme en este trabajo de graduación. Pido disculpas si olvido mencionar a alguien, a todos ustedes les reitero mi más grande agradecimiento.

Prefacio	v
Lista de figuras	x
Lista de cuadros	xi
Resumen	xiii
Abstract	xv
1. Introducción	1
2. Antecedentes	3
3. Justificación	5
4. Objetivos	7
4.1. Objetivo general	7
4.2. Objetivos específicos	7
5. Alcance	9
6. Marco teórico	11
7. Validación de Clasificadores	17
7.1. Características en el Dominio del tiempo	17
7.2. Características en el Dominio de tiempo frecuencia	18
7.3. Base de datos de sueño	20
7.3.1. Varianza	20
7.3.2. Distancia máxima mínima	20
7.3.3. Wavelets	21
8. Robot	29

9. Conclusiones	31
10.Recomendaciones	33
11.Bibliografía	35
12.Anexos	37
12.1. Planos de construcción	37

Lista de figuras

1.	Ubicación electrodos según estándar 10-20 extendido [5].	13
2.	Proceso para BCI convencionales [3]	14
3.	Representación datos de entrada en dos dimensiones y transformados [15]. . .	15
4.	Hiperplano para datos en tres dimensiones [15].	16
5.	Proceso de RNA [3]	16
6.	Matriz de confusión para SVM con kernel de función de base radial con ca- racterísticas ZC y MAV.	18
7.	Matriz de confusión para RNA con características ZC y MAV.	19
8.	Matriz de confusión para SVM con kernel de polinomio grado tres con carac- terísticas varianza y curtosis.	20
9.	Matriz de confusión para RNA con características varianza y curtosis.	21
10.	Matriz de confusión para SVM con kernel de polinomio grado tres con las cuatro características.	22
11.	Matriz de confusión para RNA con las cuatro características.	22
12.	Matriz de confusión para KNN con wavelets 2 canales.	23
13.	Matriz de confusión para SVM grado 3 con wavelets 4 canales.	23
14.	Matriz de confusión para discriminante lineal con wavelets 8 canales.	23
15.	Matriz de confusión para RN con wavelets 2 canales.	24
16.	Matriz de confusión para discriminante lineal con wavelets.	24
17.	Matriz de confusión para RN con wavelets 2 canales.	24
18.	Matriz de confusión para RN con wavelets 8 canales.	25
19.	Matriz de confusión para SVM grado 3 con wavelets para clases 0 y 1.	25
20.	Matriz de confusión para SVM grado 3 con wavelets para canales O1 y P3. . .	25
21.	Matriz de confusión para RN con wavelets para canales O1 y P3.	26
22.	Matriz de confusión para SVM grado 3 con wavelets para canales Pz y Fpz. .	26
23.	Matriz de confusión para RN con wavelets para canales Pz y Fpz.	26
24.	Matriz de confusión para SVM grado 3 con varianza.	27
25.	Matriz de confusión para RN con varianza.	27
26.	Matriz de confusión para SVM grado 3 con MMD.	27
27.	Matriz de confusión para RN con MMD.	28
28.	Matriz de confusión para SVM grado 3 con wavelets.	28
29.	Matriz de confusión para RN con wavelets.	28

30.	Modelo experimental para manipulador R17 de 5 GDL (más carrera) [16]. . .	29
-----	---	----

Lista de cuadros

1.	Clasificación Ondas Cerebrales [13] y [5]	11
2.	Parámetros de Denavit-Hartenberg para manipulador R17 de 5 GDL (más carrera).	30

Abstract

This is an abstract of the study developed under the

La tecnología ha revolucionado la vida de todos, con el desarrollo de los dispositivos electrónicos ha surgido la necesidad de mejorar la comunicación entre el ser humano y estos. La computadora es un claro ejemplo de ello, razón por la cual se inventó el teclado, el ratón, las interfaces gráficas y las interfaces cerebro computador conocidas como (BCI) por sus siglas en inglés *Brain Computer Interface*. Estas últimas empezaron a desarrollarse en 1973 y se han ido adaptando a diferentes aplicaciones biomédicas, terapéuticas, industriales, de entretenimiento y artísticas. Las BCI han mejorado la forma en que el ser humano se desenvuelve en su entorno realizando actividades de riesgo o precisión en el sector industrial, permitiendo la reinserción en la sociedad de personas con algún tipo de discapacidad y facilitando actividades a la población en general. Este trabajo consiste en diseñar e implementar una BCI no invasiva capaz de controlar dispositivos robóticos. El proceso a grandes rasgos que realiza una BCI inicia con la captura de señales electroencefalográficas (EEG), el procesamiento, la clasificación de estas y la ejecución de comandos.

Este documento busca sentar un precedente en la investigación de este tipo de interfaces en Guatemala y presentar resultados que sirvan como base y fundamento para el desarrollo de futuras fases del proyecto. Dichos resultados contribuirán a la comunidad científica internacional en temas de clasificación de señales EEG utilizando inteligencia artificial.

Se espera que este trabajo de investigación genere interés en la región y llame la atención de estudiantes potenciales a contribuir con la calidad de vida de las personas. Los resultados de esta investigación servirán como un primer acercamiento a las BCI para el lector y permitirán continuar con la investigación teniendo un punto de partida definido.

A lo largo de los años los seres humanos hemos estado intentando comprender la complejidad del cuerpo humano. Observando comportamientos, haciendo mediciones y de ahí ha surgido la necesidad de crear dispositivos capaces de medir diferentes tipos de fenómenos. Tal fue la situación de Hans Berger, reconocido neurólogo y psiquiatra alemán que en 1929 tratando de relacionar los procesos psíquicos con algún tipo de medición, logró desarrollar un dispositivo capaz de medir las fluctuaciones espontaneas en el potencial eléctrico del cerebro, conocido actualmente como electroencefalograma humano. Las mediciones realizadas por dicho dispositivo han generado interés en nuevas líneas de investigación, en la década de los 70 se empezó a investigar este tipo de señales con el fin de restaurar daños en la audición, visión y movimiento de las personas. En la década de los 90 se instalaron los primeros dispositivos neuro prostáticos que se basaban en la lectura de señales EEG [1].

A partir de ese momento se ha estado buscando mejorar la manera de interpretar dichas señales y saber diferenciar patrones en ellas. Para diferenciar patrones entre ellas y extraer características es necesario aplicar métodos matemáticos a las señales EEG en crudo. En 1973 surge un interés en la investigación de las interfaces cerebro computador (BCI), con énfasis en los métodos para el procesamiento de datos con el fin de comprender de mejor manera la actividad cerebral por el trabajo de Jacques Vidal de la Universidad de California y en los años 90 se hicieron las primeras pruebas en humanos con metodos no invasivos [1].

Parte importante de estas investigaciones es la recopilación de datos, la cual depende del tipo de equipo a utilizar. El equipo medico y profesional tiene costos muy elevados, por lo que en la investigación se ha utilizado equipos no invasivos de baja fidelidad, pero funcionales, tal es el caso de [1], [2], [3] y [4]. Parte de usar equipo relativamente económico es hacer que los estudios sean accesibles para todos, esta accesibilidad también hace referencia a comunidades de código abierto entre las mas grandes de estas se puede mencionar OpenBCI, una empresa dedicada a proveer las herramientas necesarias para medir las señales eléctricas del cuerpo a cualquiera con una computadora. En la página de la empresa se encuentra documentación abierta tanto de software como de hardware para lograr medir las señales eléctricas del cuerpo, tal y como se muestra en [1].

Gran parte de las investigaciones en la última década se han centrado en el procesamiento de las señales y los métodos para extraer las características de estas. Al principio se pensaba que las señales EEG eran valores aleatorios, pero se han ido encontrando diferentes modelos matemáticos en el dominio del tiempo, frecuencia y tiempo-frecuencia capaces de clasificar y diferenciar patrones en las señales, esto se puede observar en [5] y [3].

El procesamiento de las señales en crudo es fundamental para lograr controlar robots como en el caso de [6] que controlan un robot o en el caso de [7] y [2] que controlan prótesis de mano y brazo. El fin de controlar estos dispositivos es hacer actividades riesgosas o imposibles para los usuarios e implementarlas en robots controlándolo completamente como si fuese parte del cuerpo humano.

Respecto a la Universidad del Valle de Guatemala, se ha utilizado señales EEG para otro tipo de aplicaciones. En su mayoría la lectura de estas para una neuro retroalimentación y estimular diferentes partes del cerebro. Prueba de ello son los trabajos realizados en el 2018 [8] y [9] que utilizaron todo el equipo de OpenBCI, tanto la CytonBoard como el Ultracortex para mejorar concentración y reducir estrés en atletas de alto rendimiento. En el 2019 se trabajó con la misma CytonBoard, pero con otro tipo de sensores receptores, en este caso el ElectroCap, para generar pulsos binaurales y lograr así disminuir los desordenes del sueño en los atletas de alto rendimiento [10].

La población mundial con algún tipo de problema motriz o degenerativo ha ido aumentando en los últimos años, entre las enfermedades que los afectan cabe mencionar lesiones medulares, infarto cerebral, esclerosis, distrofia muscular, paraplejia y problemas del habla, entre otras. En Guatemala no es diferente el caso, no solamente afectan las enfermedades antes mencionadas. También existen amputaciones de miembros o extremidades por enfermedades, accidentes y por el conflicto armado interno. La mayoría de estos accidentes son de tránsito, por ejemplo, en el año 2017 se registraron 10,354 colisiones solo en la ciudad de Guatemala según el Instituto Nacional de Estadística, la causa de la mayoría es el exceso de velocidad y el uso del teléfono [11]. En cuanto a las enfermedades, gran parte de estas se da por gangrena y diabetes. Las amputaciones por el pie diabético son bastante comunes, médicos españoles aseguran que existe una probabilidad 15 veces mayor de sufrir amputación para los diabéticos en comparación con los no diabéticos [12].

Uno de los principales retos sociales en la actualidad es la atención a este segmento de personas que sufren limitaciones importantes, tienen necesidades especiales y cierto grado de dependencia. Los sistemas de salud y atención social alrededor del mundo han estado invirtiendo en hospitales, centros de rehabilitación y asistencia domiciliaria para este grupo de afectados. Todo esto con el fin único de mejorar la calidad de vida de los antes mencionados. Mejorar su bienestar y darles autonomía en actividades diarias como alimentación, aseo y trabajo. También facilitar su movilidad y comunicación con el mundo [7].

Por otro lado, también tenemos las actividades de riesgo para los seres humanos. Ya sea en ambientes hostiles o situaciones donde se requiera sustituir el trabajo humano por el trabajo robótico por motivos de eficiencia, costos o modernización. Así mismo en el ámbito de la robótica asistencial frecuentemente utilizada en los centros de rehabilitación antes mencionados y asistentes para cirugías, entre otros.

En consecuencia de lo anterior, ha surgido en el mundo la necesidad de investigar la posibilidad de controlar robots con movimientos que parezcan naturales basados en la actividad eléctrica del cuerpo humano. Los estudios con señales electromiográficas han mostrado un

gran avance y son de las más utilizadas para los casos de prótesis. Sin embargo, presentan ciertos inconvenientes como el proceso de estudio a cada paciente en específico, por el tipo de problema que tuvo y los músculos de los que se puede obtener la señal. Así mismo, cuando el paciente presenta complicaciones para mover estos músculos o ha pasado mucho tiempo después del accidente, no se pueden captar de manera correcta las señales EMG. Tomando en cuenta también que los métodos no invasivos para obtener señales EMG provocan confusión en la captación de las señales [2]. En el caso de los asistentes robóticos o control de robots en general, se necesita que al menos una extremidad este disponible para el control del robot. Lo cual hace que se pierda una extremidad para el trabajo que se esta realizando, o en el caso de pacientes con enfermedades degenerativas ni siquiera se puedan mover estas extremidades. Es por esto que a partir de la década pasada se ha mostrado interés en el control de los dispositivos con señales EEG, las cuales no presentan los problemas anteriormente mencionados.

Respecto a la Universidad del Valle de Guatemala, se cuenta con dispositivos como el robot R17, dispositivos prostéticos y dispositivos animatronicos, pero ninguno controlado por señales EEG. Tener control con señales EEG de estos, podría ayudar a cursos de carreras como ingeniería Biomédica. También se debe tomar en cuenta el interés que estos generarían en estudiantes potenciales y así continuar con las líneas de investigación de varios años del departamento, con la finalidad de entregar soluciones a la sociedad capaces de resolver problemas reales como los antes mencionados.

4.1. Objetivo general

Diseñar e implementar una interfaz cerebro-computador (BCI) que permita controlar sistemas robóticos por medio de señales electroencefalográficas (EEG).

4.2. Objetivos específicos

- Establecer un mecanismo de adquisición, filtrado y visualización en tiempo real de señales EEG.
- Seleccionar características adecuadas para el reconocimiento de patrones en señales EEG.
- Evaluar e implementar algoritmos para la clasificación de movimientos o gestos, a partir de características y patrones de señales EEG.
- Desarrollar una BCI que traduzca los resultados de la clasificación de señales en comandos para un sistema robótico.

Este proyecto consiste en el desarrollo de una primera fase de una BCI, donde se diseña e implementa una BCI no invasiva capaz de controlar dispositivos robóticos y animatrónicos en tiempo real a nivel de simulación. Para controlar dichos dispositivos se tomarán señales EEG de individuos imaginando mover las extremidades, dichas señales se procesarán y se probarán con diferentes métodos de clasificación para obtener el menor error posible. Los métodos de clasificación anteriormente mencionados se basarán en el reconocimiento de patrones con aprendizaje automático. En base a la clasificación realizada se enviarán comandos a ejecutar por el robot o dispositivo animatrónico al que esté conectado la interfaz. Cabe mencionar que esta fase no es la final del proyecto, se espera que los resultados sirvan como base para implementar el diseño físicamente y lograr controlar el dispositivo robótico con señales EEG recibidas del cerebro humano en tiempo real.

El proyecto está dividido en tres módulos principales. El primero es el encargado de la obtención de las señales electroencefalográficas en tiempo real, para este módulo se espera observar en tiempo real la actividad cerebral. El segundo modulo es el de procesamiento y clasificación de las señales. En este módulo se procesarán las señales a manera de limpiar la señal mediante filtros para luego obtener las características de estas. Estas características se utilizarán para reconocer patrones y así clasificar con aprendizaje automático. El último modulo a implementar es el desarrollo e implementación de la parte gráfica. Primero se realizará la interfaz gráfica capaz de desplegar las señales en tiempo real y las características obtenidas. Segundo, se desarrollará un simulador capaz de generar el movimiento que se espera realice el robot físico, en base a la actividad cerebral recopilada.

Ondas Cerebrales

Las ondas cerebrales son la raíz de todos nuestros pensamientos, emociones y comportamientos. Son la comunicación entre las neuronas de nuestro cerebro. Se producen cuando grupos de neuronas se comunican con otros en forma de pequeños pulsos sincronizados. Las ondas cerebrales varían según la actividad que se este relacionando, se mide en microvoltios y se clasifican según su frecuencia en (Hz). Las de frecuencias bajas se asocian al sueño y cansancio, mientras que las frecuencias altas con estrés y estado alerta [13]. En el cuadro 1 se pueden apreciar las clasificaciones que comúnmente se le hacen y el nombre con el que se les conoce, aun que en la práctica no es tan sencillo diferenciarlas.

Nombre de la Onda	Frecuencias (Hz)	Descripción
Delta	0.1-4	Son de baja frecuencia y altamente penetrantes. Se generan en alta meditación y etapas profundas del sueño. Tienen gran amplitud y se asocian con regeneración y sanación en el cuerpo. Su amplitud varia entre los 20 y 200 uV.
Theta	4-8	Se presenta en niños mayores a 13 años y en adultos que tienen complicaciones del sueño. También presente en desordenes hidrocefálicos y cuando hay altos niveles de estrés. Su amplitud varia entre los 20 y 100 uV.
Alfa	8-14	Aparece en los lados del cerebro, con una mayor amplitud en el lado dominante. Aparece al cerrar los ojos y relajarse, desaparece al abrirlos. Después de los 30 años aparece frecuentemente en la mayoría de personas. Su amplitud varía entre los 20 y 60 uV.
Beta	14-30	Aparece de manera simétrica en ambos lados del cerebro. Se acentúa con el consumo de drogas sedantes o hipnóticas. Se presenta comúnmente en pacientes con ansiedad. Su amplitud varía entre los 2 y 20 uV.
Gamma	>30	Esta frecuencia se pudo medir hasta que se implementó la tecnología digital, analógicamente era imposible. Esta frecuencia aparece en periodos de hiper alerta y altas percepciones de los sentidos.

Cuadro 1: Clasificación Ondas Cerebrales [13] y [5]

Electroencefalograma

El electroencefalograma es un estudio que monitorea la actividad electrofisiológica y registra la actividad eléctrica del cerebro. Este se relaciona con la actividad neuronal dentro del cerebro. Las señales que registra son conocidas como EEG y son fluctuaciones de voltaje que resultan de la corriente iónica entre las neuronas del cerebro en un periodo de tiempo [5].

Para captar las señales se posicionan electrodos alrededor del cerebro y se registran las diferencias de potenciales entre estos. La captación de estas señales se considera compleja, debido a que son señales estocásticas que presentan grandes variaciones dependiendo de diferentes factores como: la estructura craneal del paciente, el estado mental del mismo, niveles de concentración, movimientos musculares, movimientos involuntarios y del posicionamiento que se les dé a los electrodos [5].

Sistema de posicionamiento 10-20

El sistema internacional de posicionamiento es un estándar internacional definido por la Federación Internacional de Sociedades de Electroencefalografía (FISE) en 1958. Describe la ubicación del cráneo donde deben colocarse los electrodos para medir señales EEG. El estándar se estableció en base a la relación entre la localización del electrodo y el área de la corteza cerebral ubicada bajo el, los números 10 y 20 hacen referencia a que la distancia entre los electrodos vecinos puede ser 10 o 20 % de la distancia total entre la zona frontal y posterior, o de derecha a izquierda del cráneo, cada zona tiene asignada una letra para identificar el lóbulo y un numero para identificar en que hemisferio se encuentra, si el numero es par pertenece al hemisferio derecho y si es impar al hemisferio izquierdo. Cada lóbulo del cerebro se puede identificar con una letra correspondiente. Para los lóbulos frontal, temporal, central, parietal y occipital sus identificadores son F, T, C, P, O respectivamente [5].

Por lo regular se utilizan cuatro referencias anatómicas para posicionar los electrodos. La primera es el nasión, este es el punto entre el hueso frontal y los dos huesos de la nariz del cráneo. El segundo es el inion, este se encuentra en el punto inferior trasero del cráneo y es la proyección mas prominente del hueso occipital. Por ultimo los puntos preauriculares detrás de los oídos [5]. En la Figura 1 se puede apreciar gráficamente la ubicación de los electrodos para un sistema 10-20. El estándar 10-20 es para una cantidad pequeña de electrodos, normalmente 21. Con la necesidad de más ondas y más canales se han establecido nuevos estándares como el 10-10 y 10-5 para 81 y 256 canales, respectivamente.

Interfaz Cerebro Computador

La interfaz cerebro computador (BCI) por sus siglas en inglés Brain Computer Interface es capaz de medir la actividad cerebral y traducirlas para poder procesarlas con una computadora. El objetivo principal de estas es monitorear y estudiar la actividad cerebral ante diferentes escenarios. El estudio de la actividad cerebral se logra mediante las señales




Figura 1: Ubicación electrodos según estándar 10-20 extendido [5].

EEG y la calidad de estas depende del equipo de medición a utilizar. La diferencia en el tipo de señales a obtener depende de los equipos a utilizar. Existe una gran variedad de dispositivos para captar las señales, por un lado, están los dispositivos clínicos y médicos que entregan mejor calidad de señales, pero su costo es bastante elevado. Por otro lado, tenemos los equipos portátiles utilizados comúnmente para proyectos de investigación y desarrollo, pero nunca podrán sustituir a los dispositivos médicos [5].

Un sistema BCI esta conformado por varias etapas tal y como se observa en la Figura 2. La primera de ellas seria la adquisición de señales EEG en crudo, esto se puede realizar en tiempo real o guardar para un análisis posterior. La siguiente etapa sería el preprocesamiento donde se aplican filtros por lo regular para separar frecuencias y eliminar ruido o frecuencias no deseadas como la de la corriente eléctrica (60 Hz). Luego está la extracción de características lo cual se considera el procesamiento en sí, estas características se obtienen mediante métodos matemáticos como la transformada rápida de Fourier (FFT), transformada de ondículas (Wavelets), transformada de Hilbert-Huang, número de cruces por cero (*Zero Crossing ZC*) o el promedio del valor absoluto (*Mean Absolute Value MAV*). Siguiendo a esto, tenemos la etapa de clasificación e interpretación de las características obtenidas mediante aprendizaje automático. Por último, tenemos la señal de salida al actuador o efector, dependiendo de la clasificación realizada anteriormente [5].

Tipos de BCI

Invasivo: Necesitan de neurocirugías para poder instalarlos en la materia gris. La señal es de muy buena calidad, pero con el tiempo la señal se va degradando porque el cuerpo lo rechaza y forma cicatrices [5].

Parcialmente invasivo: Se implantan dentro del cráneo, pero no en la materia gris mediante cirugías. Su calidad se considera intermedia, pero no se degradan con el paso del

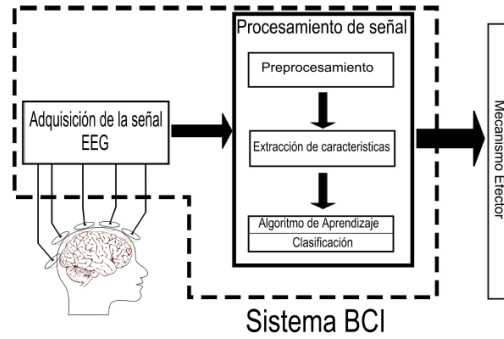


Figura 2: Proceso para BCI convencionales [3]

tiempo porque el cuerpo no los rechaza [5].

No invasivo: La mayoría de los trabajos de investigación y desarrollo en los últimos años se realizan con esta tecnología. Son sencillos de instalar, remover y no requieren cirugías. Sin embargo, la calidad de las señales no es tan buena como las mencionadas anteriormente y no se pueden detectar señales de alta frecuencia [5].

Aprendizaje automático

El aprendizaje automático, comúnmente conocido como *Machine Learning* es el estudio científico de algoritmos y modelos estadísticos que las computadoras utilizan para tomar decisiones sin ser programadas explícitamente. Según el doctor Adeel Najmi es cuando las maquinas pueden crear o refinar autónomamente modelos de decisión [14]. Esta nace como una subdisciplina de la Inteligencia Artificial (IA) que construye modelos matemáticos basado en los datos que se le proporcionan, conocidos como datos de entrenamiento para posteriormente realizar toma de decisiones o predicciones. Entre las aplicaciones principales se encuentran: reconocimiento de imágenes, sonido y texto, diagnósticos médicos, predicción de eventos, minería de datos, robótica, finanzas, telecomunicaciones y biomédica [14].

El proceso de machine learning se podría dividir en dos procesos. El primer proceso de decisión y ejecución. El segundo proceso de aprendizaje por medio de la retroalimentación. Ambas trabajan de la mano para lograr la mejora continua y poder tomar las mejores decisiones o predicciones sin haberlo programado explícitamente [14]. Existen diferentes tipos de algoritmos de aprendizaje automático que se utilizan como clasificadores, a continuación se detallan dos de ellos.

Máquina de Soporte Vectorial

Una Máquina de Soporte Vectorial conocida con el acrónimo SVM por sus siglas en inglés (*Support Vector Machine*) es un algoritmo de aprendizaje automático supervisado que suele emplearse con fines de clasificación y regresión binaria tal y como se observa en la Figura 3. En la actualidad se implementa el algoritmo para resolver problemas de regresión, agrupamiento y multclasificación. Por su alto rendimiento se ha implementado en visión

artificial, reconocimiento de patrones y análisis de series temporales [10].




Figura 3: Representación datos de entrada en dos dimensiones y transformados [15].

El algoritmo construye un modelo a partir de ejemplos de entrenamiento ya clasificados, capaz de predecir a que categoría pertenecerá un nuevo ejemplo. El funcionamiento del SVM se basa en encontrar la mejor línea recta, plano o hiperplano según la dimensión del problema que divida el conjunto de datos en dos clases, lo cual consigue aplicando los siguientes conceptos [15], los cuales se observan en la Figura 4.

- **Hiperplano:** Plano que separa y clasifica linealmente un conjunto de datos.
- **Vectores de apoyo:** Son los puntos críticos de datos más cercanos a la línea del hiperplano y que al eliminarse alterarían la posición del este.
- **Margen:** Distancia entre el hiperplano y el dato más cercano de cualquiera de los conjuntos.
- **Dimensión VC:** Cuyo nombre se deriva de quienes contribuyeron con grandes aportes para los SVM (Vapnik-Chervonekis). VC es el conjunto de funciones disponibles y la dimensión es la cantidad máxima de puntos que se pueden separar de todas las formas posibles mediante el conjunto VC. A mayor dimensión, menor error del conjunto de entrenamiento y mayor confianza.
- **Kernel:** También conocido como núcleo es el conjunto de funciones matemáticas utilizadas para transformar los datos de entrada en la forma deseada. Conectan la linealidad y no linealidad de las SVM, cuando los datos parecen no tener forma de separarlos.

Redes Neuronales Artificiales

Conocidas por el acrónimo RNA, el nombre proviene de sus similitudes en organización, comportamiento y estructura con su homólogo biológico. Por ser un tipo de aprendizaje automático supervisado, esta herramienta aprende y se forma a sí misma tratando de minimizar la función de pérdida que evalúa a la red en su totalidad mediante propagación hacia atrás. Tratando de emular el sistema neuronal biológico, las neuronas artificiales se organizan en capas y las capas en una estructura jerárquica similar a la del cerebro[3], tal y como se aprecia en la Figura 5.

Las redes neuronales artificiales emulan los siguientes conceptos clave:




Figura 4: Hiperplano para datos en tres dimensiones [15].




Figura 5: Proceso de RNA [3]

- **Procesamiento Paralelo:** Debido a la gran cantidad de neuronas que intervienen en un proceso, es posible efectuar procesos en paralelo.
- **Memoria Distribuida:** La información está distribuida por la sinapsis de la red, existiendo redundancia en caso falle o se dañe alguna sinapsis.
- **Adaptabilidad al entorno:** Es posible conceptualizar a partir de casos previos y aprender en base a la experiencia proporcionada por la información de las sinapsis.

Los conceptos claves en los que se basa la red neuronal artificial hacen que sea ampliamente utilizada para implementar clasificadores con aprendizaje automático [3].

7.1. Características en el Dominio del tiempo

Después de haber extraído la información de los 64 canales de la base de datos, se procedió a seleccionar solamente los canales de interés para el trabajo. Los cuales son C3, C1, Cz, C2 y C4 según la Figura 1. Luego de extraer los datos de estos cinco canales, se procedió a extraer las características. Al inicio se extrajeron solamente el número de cruce por ceros (ZC) y el valor absoluto promedio (MAV). Sin embargo, como se puede observar en las Figuras 6 y 7 al aplicar SVM y RNA respectivamente, ninguno presenta resultados aceptables. Importante mencionar que para todos los resultados con SVM presentados a continuación se utilizó el 90 % de las muestras para entrenar y el 10 % para evaluar, de las 45 muestras obtenidas. Los resultados obtenidos con RNA se obtuvieron utilizando un tamaño de capa oculta de 10, la función de entrenamiento SCG debido al balance de consumo de memoria y calidad de resultados que presenta. Se utilizó un 80 % de las muestras para entrenar, 10 % para validar y 10 % para probar. En cuanto a las etiquetas utilizadas 1 y 2 se refieren a abrir y cerrar el puño izquierdo y derecho, respectivamente. Para SVM se tuvo que cambiar el 2 por el 0 para poder obtener de manera automática la matriz de confusión.

Debido a que los resultados de los clasificadores no eran los esperados, se procedió a calcular 2 características más las cuales son varianza y curtosis. Con estas dos características se obtuvieron mejores resultados para ambos clasificadores, los cuales se pueden observar en las Figuras 8 y 9 para SVM y RNA, respectivamente.

En busca de mejorar el rendimiento de los clasificadores, se procedió a utilizar las cuatro características a la vez. Sin embargo, los resultados obtenidos son muy similares a los obtenidos solamente con varianza y curtosis. Los resultados se pueden apreciar en las Figuras 10 y 11.




Figura 6: Matriz de confusión para SVM con kernel de función de base radial con características ZC y MAV.

Como se puede observar los resultados aun no son los deseados, a pesar que para el caso de SVM se eligió el núcleo que mejor resultado presentó siendo RBF para ZC, MAV y polinomio grado 3 para varianza, curtosis y las cuatro características juntas. Los resultados fueron mejorando, sin embargo, se procederá a probar con características en el dominio de la frecuencia cómo Transformada Rápida de Fourier o Wavelets, las cuales se espera den mejores resultados.

7.2. Características en el Dominio de tiempo frecuencia

Por instucciones del asesor se implemento el clasificador en el dominio de la frecuencia, aplicando Wavelets a las misma base de datos en lugar de características en el dominio del tiempo.

Se inicio trabajando con los canales C3, C1, C6, Cp5, T9, T10, Poz y Po4. Luego separar los canales por sus bandas de frecuencia con el uso de Wavelets para observar su dispersión en el tiempo se procedió a utilizar la aplicación de *Classification Learner* de *MATLAB* para observar que tipo de clasificador presentaba mejor rendimiento. Se realizaron pruebas para los primeros 2 canales, los primeros 4 canales y los 8 canales mencionados anteriormente obteniendo el mejor rendimiento para cada prueba con los metodos de K-vecinos cercanos, SVM kernel cubico y discriminante lineal, tal y como se observa en las figuras 12, 13, 16, respectivamente.

Como se puede observar en las figuras 12, 13, 16 los resultados del clasificador no son los esperados, independientemente del clasificador porque al utilizar redes neuronales tampoco se logro el rendimiento deseado tal y como se muestra en las figuras 17 y 18. Los motivos por los cuales pudo no funcionar fue que con 2 canales existían muy pocos datos para clasificar correctamente. Al utilizar 4 y 8 canales se tuvo el problema que al concatenar las

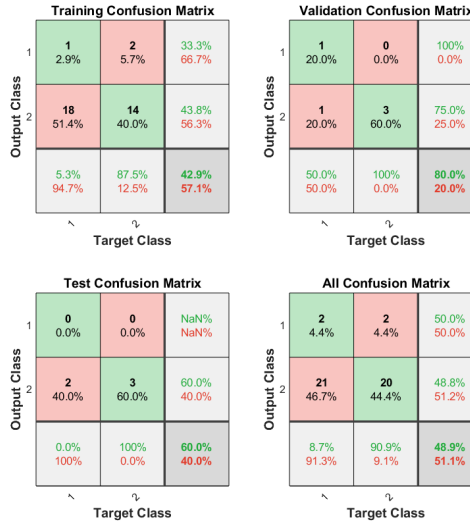


Figura 7: Matriz de confusión para RNA con características ZC y MAV.

características de todos los canales juntas el número de características era mayor al número de muestras, un problema conocido en aprendizaje automático como sobrecarga de datos.

Con estos resultados se observó que el clasificador SVM grado 3 presentaba siempre los mejores resultados o por lo menos estaba entre los primeros 3 al utilizar la aplicación de *MATLAB* por lo que se decidió utilizar solamente ese clasificador para las siguientes pruebas. Acompañado de redes neuronales como se había hecho desde un principio.

Por lo que se procedió a implementar un clasificador binario que en lugar de decidir entre 3 clases como las pruebas anteriores, solo tuviera que separar en 2 clases con 2 canales esperando obtener mejores resultados.

Se probaron las diferentes combinaciones de clases y los mejores resultados se obtuvieron al clasificar las clases 0 y 1, cuya matriz de confusión se muestra en la figura 19. Como se puede observar los resultados aún no son los esperados, el clasificador en todas las pruebas muestra estar sesgado hacia la clase 0 esto se puede deber a que el número de muestras es el doble en comparación a las otras clases.

Se finalizaron las pruebas y no se obtuvo el resultado esperado por parte de los clasificadores, por lo que se optó por utilizar diferentes canales, en esta ocasión el O1 y el P3. Se obtuvieron los resultados que se muestran en las figuras 20 y 21, para SVM y redes neuronales, respectivamente.

Luego de extraer características por medio de wavelets y aplicar los clasificadores de SVM kernel cúbico y Redes Neuronales, aún no se obtienen los resultados esperados. Por lo que se opta, por elegir diferentes canales, siendo estos el Pz y el Fpz. Los resultados se pueden observar en las figuras 22 y 23, para SVM y redes neuronales, respectivamente.

Al finalizar estas pruebas se puede ver que los clasificadores no presentan buen rendimiento, esto se puede deber a los pocos datos con los que se cuenta en la base de datos. Por




Figura 8: Matriz de confusión para SVM con kernel de polinomio grado tres con características varianza y curtosis.

lo que se buscara otra base de datos para validar el funcionamiento de los clasificadores.

7.3. Base de datos de sueño

Debido a los malos resultados obtenidos con la base de datos anterior, se procedió a buscar otra base de datos con la cual se pudieran validar los clasificadores. Se eligió la base de datos de sueño de Physionet, debido a que tiene gran cantidad de señales EEG y están correctamente identificadas según sus clases, por lo que el tamaño de las señales no sería una limitante para el rendimiento de los clasificadores.

7.3.1. Varianza

Se inició analizando la base de datos en el dominio del tiempo las características que se extrajeron fueron 5, las cuales son: Valor absoluto promedio, número de cruces por cero, varianza, potencia media y curtosis. Para las 4 señales proporcionadas cuyos nombres son fpz, pz, eog y emg. Se extrajeron épocas equivalentes a 30 segundos, tomando en cuenta que las grabaciones fueron hechas a una frecuencia de 100 Hz. Luego de extraer las características se procedió a implementar los clasificadores, los resultados que se obtuvieron se muestran en las figuras 24 y 25, para SVM y redes neuronales, respectivamente.

7.3.2. Distancia máxima mínima

A pesar de obtener buenos resultados, se buscó mejorar utilizando otro tipo de características en el dominio del tiempo. Se utilizó la mayoría de características anteriores, a

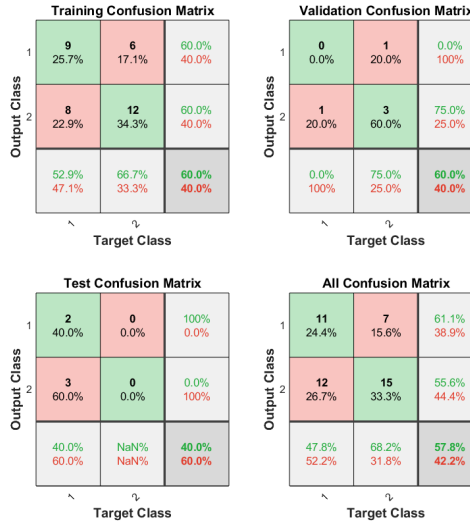


Figura 9: Matriz de confusión para RNA con características varianza y curtosis.

diferencia que se sustituyo la varianza por la entropía de la señal y se obtuvieron los siguientes resultados que se muestran en las figuras 26 y 27 , para SVM y redes neuronales, respectivamente.

7.3.3. Wavelets

Por último, se probó clasificar las señales con característica en el dominio tiempo-frecuencia aplicando wavelets, en lugar de las 5 características extraídas anteriormente en el dominio del tiempo. Cuyos resultados se pueden observar en las figuras 28 y 29 , para SVM y redes neuronales, respectivamente.

Luego de analizar los resultados de todas las pruebas, se procede a elegir Maquinas de Soporte Vectorial de la segunda prueba. Utilizando la entropía de la señal, pues presenta de los mejores resultados de clasificación a pesar de ser en el dominio del tiempo, lo cual se puede considerar como una ventaja por su fácil implementación en señales en tiempo real y bajo coste computacional.

Confusion Matrix				
Output Class	0	1		
	2 40.0%	0 0.0%	100% 0.0%	
	0 0.0%	3 60.0%	100% 0.0%	
		0	1	
		100% 0.0%	100% 0.0%	100% 0.0%
		Target Class		

Figura 10: Matriz de confusión para SVM con kernel de polinomio grado tres con las cuatro características.

Training Confusion Matrix

Output Class	1	5 14.3%	1 2.9%	83.3% 16.7%
	2	13 37.1%	16 45.7%	55.2% 44.8%
		27.8% 72.2%	94.1% 5.9%	60.0% 40.0%
		Target Class		

Validation Confusion Matrix

Output Class	1	2 40.0%	1 20.0%	66.7% 33.3%
	2	0 0.0%	2 40.0%	100% 0.0%
		100% 0.0%	66.7% 33.3%	80.0% 20.0%
		Target Class		

Test Confusion Matrix

Output Class	1	0 0.0%	1 20.0%	0.0% 100%
	2	3 60.0%	1 20.0%	25.0% 75.0%
		0.0% 100%	50.0% 50.0%	20.0% 80.0%
		Target Class		

All Confusion Matrix

Output Class	1	7 15.6%	3 6.7%	70.0% 30.0%
	2	16 35.6%	19 42.2%	54.3% 45.7%
		30.4% 69.6%	86.4% 13.6%	57.8% 42.2%
		Target Class		

Figura 11: Matriz de confusión para RNA con las cuatro características.




Figura 12: Matriz de confusión para KNN con wavelets 2 canales.




Figura 13: Matriz de confusión para SVM grado 3 con wavelets 4 canales.




Figura 14: Matriz de confusión para discriminante lineal con wavelets 8 canales.




Figura 15: Matriz de confusión para RN con wavelets 2 canales.




Figura 16: Matriz de confusión para discriminante lineal con wavelets.




Figura 17: Matriz de confusión para RN con wavelets 2 canales.




Figura 18: Matriz de confusión para RN con wavelets 8 canales.




Figura 19: Matriz de confusión para SVM grado 3 con wavelets para clases 0 y 1.




Figura 20: Matriz de confusión para SVM grado 3 con wavelets para canales O1 y P3.

Matriz de confusión RN

0		112	24	29		100.0%
1		62	9	17	70.5%	29.5%
2		59	7	11	9.1%	90.9%
3						
		26.6%	17.5%			
		73.4%	82.5%	100.0%		
		0	1	2	3	

Predicted Class

Figura 21: Matriz de confusión para RN con wavelets para canales O1 y P3.

Matriz de confusión SVM grado 3

0	86	5	74	52.1%	47.9%
1	51	14	23	15.9%	84.1%
2	49	4	24	31.2%	68.8%
	46.2%	60.9%	19.8%		
	53.8%	39.1%	80.2%		
	0	1	2		

Predicted Class

Figura 22: Matriz de confusión para SVM grado 3 con wavelets para canales Pz y Fpz.

Matriz de confusión RN

0		91	13	61		100.0%
1		57	13	18	64.8%	35.2%
2		42	11	24	14.3%	85.7%
3						
		30.0%	29.7%			
		70.0%	70.3%	100.0%		
		0	1	2	3	

Predicted Class

Figura 23: Matriz de confusión para RN con wavelets para canales Pz y Fpz.

	1	2	3	4	5		
1	28	3				90.3%	9.7%
2	5	6			6	35.3%	64.7%
3		6	65		4	86.7%	13.3%
4	1		9	56		84.8%	15.2%
5					37	100.0%	
	82.4%	40.0%	87.8%	100.0%	78.7%		
	17.6%	60.0%	12.2%		21.3%		
	1	2	3	4	5		

Figura 27: Matriz de confusión para RN con MMD.

	0	1	2	3	4			
0	336	2	1	32	1		90.3%	9.7%
1	4	736	90	32	38		81.8%	18.2%
2	2	95	693		2		87.5%	12.5%
3	39	32		112	21		54.9%	45.1%
4	1	6		16	421		94.8%	5.2%
	88.0%	84.5%	88.4%	58.3%	87.2%			
	12.0%	15.5%	11.6%	41.7%	12.8%			
	0	1	2	3	4			
	Predicted Class							

Figura 28: Matriz de confusión para SVM grado 3 con wavelets.

	1	2	3	4	5		
1	327		2	43		87.9%	12.1%
2	4	682	124	32	58	75.8%	24.2%
3	3	81	706	2		89.1%	10.9%
4	59	32		89	24	43.6%	56.4%
5	5	7	3	15	414	93.2%	6.8%
	82.2%	85.0%	84.6%	49.2%	83.5%		
	17.8%	15.0%	15.4%	50.8%	16.5%		
	1	2	3	4	5		

Figura 29: Matriz de confusión para RN con wavelets.

El propósito de este capítulo es lograr demostrar el correcto funcionamiento del clasificador e interfaz desarrollados. Para lograr lo antes mencionado se decidió que se utilizaría el manipulador R17 que posee el Departamento de Ingeniería Electrónica, Mecatrónica y Biomédica de la UVG, el cual se muestra en la Figura 30. Para validar que la BCI es capaz de generar comandos específicos para el robot, a partir de señales EEG. Debido a la situación de la pandemia del COVID-19, es imposible acceder al robot físico en la UVG. Por lo que se propone desarrollar el modelo del robot en MATLAB y validar el correcto funcionamiento de la BCI a nivel simulación, con el fin de sustituir esta parte de simulación, por el robot de los laboratorios para proximas fases del proyecto.



Figura 30: Modelo experimental para manipulador R17 de 5 GDL (más carrera) [16].

Para implementar la simulación del modelo del robot se utilizo MATLAB y la toolbox de robotica de Peter Corke. Como primer paso se establecieron los parametros de Denavit-Hartenberg del R17, los cuales se muestran en el Cuadro 2 .

θ_j	d_j	a_j	α_j
0	q_1	0	$-\pi/2$
$q_2 + \pi/2$	-0.355	0	$-\pi/2$
$q_3 + \pi/2$	0	0.375	0
q_4	0	0.375	0
$q_5 - \pi/2$	0	0	$-\pi/2$
$q_6 + \pi/2$	0	0	0

Cuadro 2: Parámetros de Denavit-Hartenberg para manipulador R17 de 5 GDL (más carrera).

CAPÍTULO 9

Conclusiones

CAPÍTULO 10

Recomendaciones

- [1] P. Schembri, R. Anthony y M. Pelc, “Detection of Electroencephalography Artefacts using Low Fidelity Equipment”, ene. de 2017, págs. 65-75. DOI: 10.5220/0006398500650075.
- [2] K. Correa Arana y A. Vivas Alban, “Protesis de mano virtual movida por señales encefalográficas EEG”, es, *Prospectiva*, vol. 14, págs. 99-110, dic. de 2016, ISSN: 1692-8261. dirección: http://www.scielo.org.co/scielo.php?script=sci_arttext&pid=S1692-82612016000200099&nrm=iso.
- [3] R. Sepúlveda, M. Oscar, G. Díaz, D. Gutierrez y O. Castillo, “Clasificación de señales encefalográficas mediante redes neuronales artificiales”, Español, *Computación y Sistemas*, 2015, ISSN: 1405-5546. dirección: <https://www.redalyc.org/articulo.oa?id=61536854006>.
- [4] J. Esqueda Elizondo, L. Hernández-Manzo y M. Pinto-Ramos, “Manipulación de un brazo robótico mediante señales electroencefalográficas”, *Revista de Tecnología e Innovación*, vol. 3, págs. 89-98, jun. de 2016.
- [5] L. J. Gómez Figueroa, “Análisis de señales EEG para detección de eventos oculares, musculares y cognitivos”, págs. 1-14, 2016.
- [6] S. Brewster, *Un robot dirigido con la mente ayuda con telepresencia a personas discapacitadas*, Visitado por última vez 04 de abril de 2020., 2015. dirección: <https://www.technologyreview.es/s/5373/un-robot-dirigido-con-la-mente-ayuda-con-telepresencia-personas-discapacitadas>.
- [7] R. Ceres, M. A. Mañanas y J. M. Azorín, “Interfaces y Sistemas en Rehabilitación y Compensación Funcional para la Autonomía Personal y la Terapia Clínica”, *Revista Iberoamericana de Automática e Informática industrial*, vol. 8, n.º 2, págs. 5-15, 2011, ISSN: 1697-7920. DOI: 10.1016/S1697-7912(11)70021-8. dirección: <https://polipapers.upv.es/index.php/RIAI/article/view/8576>.
- [8] J. Aguirre, “Diseño, Análisis, y Desarrollo de un Sistema de Entrenamiento para Mejorar el Desempeño de los Atletas del Comité Olímpico Guatemalteco”, 2018.

- [9] M. Godoy, “Diseño e implementación de módulo de recopilación de señales y módulo de retroalimentación”, 2018.
- [10] J. P. Muñoz, “Diseño de un sistema inteligente de monitoreo de ondas EEG y generador de pulsos binaurales para combatir desórdenes de sueño en los atletas”, págs. 1-54, 2019.
- [11] D. L. Hora, *La probabilidad de sufrir una amputación de pie es 15 veces mayor en un diabético, según experto*, Visitado por última vez 04 de abril de 2020., 2018. dirección: <https://www.elpais.cr/2018/07/28/los-retos-de-vivir-con-una-protesis-en-guatemala/>.
- [12] P. Pernas, *Los retos de vivir con una prótesis en Guatemala*, Visitado por última vez 04 de abril de 2020., 2019. dirección: <https://lahora.gt/la-probabilidad-de-sufrir-una-amputacion-de-pie-es-15-veces-mayor-en-un-diabetico-segun-experto/>.
- [13] Brainworks, *WHAT ARE BRAINWAVES?*, Visitado por última vez 04 de abril de 2020. dirección: <https://brainworksneurotherapy.com/what-are-brainwaves>.
- [14] A. Najmi, *WHAT IS MACHINE LEARNING?*, Visitado por última vez 04 de abril de 2020., 2017. dirección: <https://supplychainbeyond.com/what-is-machine-learning/>.
- [15] Numerentur, *Máquina de Soporte Vectorial SVM*, Visitado por última vez 03 de junio de 2020., 2018. dirección: <http://numerentur.org/svm/>.
- [16] *R17 Robot Manual*, ST Robotics, Cambridge, Reino Unido, 2017.

CAPÍTULO 12

Anexos

12.1. Planos de construcción

