
Interfaz Biomédica para el Control de Sistemas Robóticos Utilizando Señales EEG

Rodrigo Ralda González



UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería



**Interfaz Biomédica para el Control de Sistemas Robóticos
Utilizando Señales EEG**

Trabajo de graduación presentado por Rodrigo Ralda González para
optar al grado académico de Licenciado en Ingeniería Mecatrónica

Guatemala,

2020

Vo.Bo.:

(f) _____
Dr. Luis Alberto Rivera Estrada

Tribunal Examinador:

(f) _____
Dr. Luis Alberto Rivera Estrada

(f) _____

(f) _____

Fecha de aprobación: Guatemala, de diciembre de 2020.

Esta investigación surgió de la oportunidad de pertenecer a la línea de investigación biomédica de la universidad y mi interés por controlar dispositivos robóticos a partir de señales cerebrales. A medida que la tecnología ha estado avanzando, también lo han hecho los proyectos inclusivos que buscan reinsertar a personas con algún tipo de discapacidad a la sociedad. Este es el caso de este proyecto, que espera generar interés en futuras generaciones para aplicar las interfaces cerebro computador en prótesis, equipo de rehabilitación o equipo industrial.

Culminar este trabajo de graduación no hubiera sido posible sin el apoyo de varios. Primero que todo agradecer a Dios por haberme guiado, apoyado y darme fortaleza en los momentos difíciles. Quiero agradecer a mis padres César y Michelle, hermano Javier, abuelos y familia en general por creer en mí desde el principio y siempre apoyarme incondicionalmente con amor. También agradecer a mis amigos y compañeros de estudios y felicitarlos por haber culminado este logro tan importante en nuestro desarrollo profesional. Por último, agradecer a la Universidad del Valle de Guatemala y al grupo de profesionales que contribuyeron con el desarrollo de mi carrera, especialmente al Dr. Luis Rivera por su dedicación y paciencia en compartirme sus conocimientos y guiarme en este trabajo de graduación. Pido disculpas si olvido mencionar a alguien, a todos ustedes les reitero mi más grande agradecimiento.

Prefacio	III
Lista de figuras	VII
Lista de cuadros	VIII
Resumen	IX
Abstract	X
1. Introducción	1
2. Antecedentes	3
3. Justificación	5
4. Objetivos	7
4.1. Objetivo general	7
4.2. Objetivos específicos	7
5. Alcance	8
6. Marco teórico	10
6.1. Ondas Cerebrales	10
6.2. Electroencefalograma	10
6.3. Sistema de posicionamiento 10-20	11
6.4. Interfaz Cerebro Computador	12
6.4.1. Tipos de BCI	13
6.5. Aprendizaje automático	13
6.5.1. Máquina de Soporte Vectorial	14
6.5.2. Redes Neuronales Artificiales	14
6.6. Extracción de características	16
6.6.1. Valor Absoluto Promedio	16
6.6.2. Número de Cruces por Cero	16

6.6.3.	Curtosis	16
6.6.4.	Varianza	17
6.6.5.	Potencia Media	17
6.6.6.	Distancia Máxima Mínima	17
6.6.7.	Ondículas	17
6.7.	Manipulador Serial	18
6.8.	Procesamiento de Señales	19
7.	Validación de Clasificadores	20
7.1.	Características en el Dominio del tiempo	20
7.2.	Características en el Dominio de tiempo frecuencia	21
7.3.	Base de datos de sueño	23
7.3.1.	Varianza	23
7.3.2.	Distancia máxima mínima	23
7.3.3.	Wavelets	24
8.	Visualización Gráfica	32
8.1.	Robot	32
8.1.1.	R17	32
8.1.2.	UR5	34
8.1.3.	Puma 560	35
8.2.	Interfaz gráfica	37
8.2.1.	Control Manual	37
8.2.2.	Control Automático	38
9.	Conclusiones	40
10.	Recomendaciones	41
11.	Bibliografía	42
12.	Anexos	45
12.1.	Planos de construcción	45
13.	Glosario	46

Lista de figuras

1.	Ubicación electrodos según estándar 10-20 extendido [5].	12
2.	Proceso para BCI convencionales [3]	13
3.	Representación datos de entrada en dos dimensiones y transformados [15]. . .	14
4.	Hiperplano para datos en tres dimensiones [15].	15
5.	Proceso de RNA [3]	15
6.	Tipos de juntas, q_1 revoluta y q_2 prismática [23]	18
7.	Señal continua y discreta [24]	19
8.	Diagrama de bloques Procesamiento Digital de Señales [25]	19
9.	Matriz de confusión para SVM con kernel de función de base radial con características ZC y MAV.	21
10.	Matriz de confusión para RNA con características ZC y MAV.	22
11.	Matriz de confusión para SVM con kernel de polinomio grado tres con características varianza y curtosis.	23
12.	Matriz de confusión para RNA con características varianza y curtosis.	24
13.	Matriz de confusión para SVM con kernel de polinomio grado tres con las cuatro características.	25
14.	Matriz de confusión para RNA con las cuatro características.	25
15.	Matriz de confusión para KNN con wavelets 2 canales.	26
16.	Matriz de confusión para SVM grado 3 con wavelets 4 canales.	26
17.	Matriz de confusión para discriminante lineal con wavelets 8 canales.	26
18.	Matriz de confusión para RN con wavelets 2 canales.	27
19.	Matriz de confusión para discriminante lineal con wavelets.	27
20.	Matriz de confusión para RN con wavelets 2 canales.	27
21.	Matriz de confusión para RN con wavelets 8 canales.	28
22.	Matriz de confusión para SVM grado 3 con wavelets para clases 0 y 1.	28
23.	Matriz de confusión para SVM grado 3 con wavelets para canales O1 y P3. . .	28
24.	Matriz de confusión para RN con wavelets para canales O1 y P3.	29
25.	Matriz de confusión para SVM grado 3 con wavelets para canales Pz y Fpz. .	29
26.	Matriz de confusión para RN con wavelets para canales Pz y Fpz.	29
27.	Matriz de confusión para SVM grado 3 con varianza.	30
28.	Matriz de confusión para RN con varianza.	30
29.	Matriz de confusión para SVM grado 3 con MMD.	30

30.	Matriz de confusión para RN con MMD.	31
31.	Matriz de confusión para SVM grado 3 con wavelets.	31
32.	Matriz de confusión para RN con wavelets.	31
33.	Manipulador Serial R17 de 5 GDL (más carrera) [26].	33
34.	Configuración de juntas según clase para R17.	34
35.	Juntas manipulador serial UR5 [27].	35
36.	Configuración de juntas según clase para UR5.	36
37.	Juntas manipulador serial Puma 560 [29].	36
38.	Configuración de juntas según clase para Puma 560.	37
39.	Pestaña modo manual.	38
40.	Pestaña modo automático.	39

Lista de cuadros

1.	Clasificación Ondas Cerebrales, [13] y [5].	11
2.	Parámetros de Denavit-Hartenberg para manipulador R17 de 5 GDL (más carrera).	33
3.	Configuración de juntas R17 para cada clase.	34
4.	Configuración de juntas UR5 para cada clase.	35
5.	Configuración de juntas Puma 560 para cada clase.	36

[[PENDIENTE]]

[[PENDIENTE]]

La tecnología ha revolucionado la vida de todos. Con el desarrollo de los dispositivos electrónicos ha surgido la necesidad de mejorar la comunicación entre el ser humano y estos. La computadora es un claro ejemplo de ello, razón por la cual se inventó el teclado, el ratón, las interfaces gráficas y las interfaces cerebro computador (*Brain Computer Interface*, BCI). Estas últimas empezaron a desarrollarse en 1973 y se han ido adaptando a diferentes aplicaciones biomédicas, terapéuticas, industriales, de entretenimiento y artísticas. Las BCI han mejorado la forma en que el ser humano se desenvuelve en su entorno realizando actividades de riesgo o precisión en el sector industrial, permitiendo la reinserción en la sociedad de personas con algún tipo de discapacidad y facilitando actividades a la población en general. Este trabajo consiste en diseñar e implementar una BCI no invasiva capaz de controlar dispositivos robóticos. El proceso que realiza una BCI inicia con la captura de señales electroencefalográficas (EEG), el procesamiento, la clasificación de estas y la ejecución de comandos.

****[[PARAFRASEAR LOS OBJETIVOS GENERAL Y ESPECÍFICOS]]**

Este trabajo de investigación consiste en diseñar e implementar una interfaz cerebro-computador (BCI) que cuente con un mecanismo capaz de capturar, filtrar y visualizar señales EEG en tiempo real. Luego, seleccionar características adecuadas para implementar algoritmos de clasificación automática y en base a esta clasificación enviar los comandos respectivos al sistema robótico que se desee.

Este documento busca sentar un precedente en la investigación de este tipo de interfaces en Guatemala y presentar resultados que sirvan como base y fundamento para el desarrollo de futuras fases del proyecto. Dichos resultados contribuirán a la comunidad científica internacional en temas de clasificación de señales EEG utilizando inteligencia artificial.

Se espera que este trabajo de investigación genere interés en la región y llame la atención de estudiantes potenciales a contribuir con la calidad de vida de las personas. Los resultados de esta investigación servirán como un primer acercamiento a las BCI para el lector y permitirán continuar con la investigación teniendo un punto de partida definido.

[[MENCIONAR LO QUE SE PRESENTARÁ EN ESTE DOCUMENTO, ES DECIR,
CÓMO ESTÁ ORGANIZADO EL MISMO.]]

A lo largo de los años los seres humanos hemos estado intentando comprender la complejidad del cuerpo humano. Observando comportamientos, haciendo mediciones y de ahí ha surgido la necesidad de crear dispositivos capaces de medir diferentes tipos de fenómenos. Tal fue la situación de Hans Berger, reconocido neurólogo y psiquiatra alemán que en 1929 tratando de relacionar los procesos psíquicos con algún tipo de medición, logró desarrollar un dispositivo capaz de medir las fluctuaciones espontaneas en el potencial eléctrico del cerebro, conocido actualmente como electroencefalograma humano. Las mediciones realizadas por dicho dispositivo han generado interés en nuevas líneas de investigación, en la década de los 70 se empezó a investigar este tipo de señales con el fin de restaurar daños en la audición, visión y movimiento de las personas. En la década de los 90 se instalaron los primeros dispositivos neuro prostáticos que se basaban en la lectura de señales EEG [1].

A partir de ese momento se ha estado buscando mejorar la manera de interpretar dichas señales y saber diferenciar patrones en ellas. Para diferenciar patrones entre ellas y extraer características es necesario aplicar métodos matemáticos a las señales EEG en crudo. En 1973 surge un interés en la investigación de las interfaces cerebro computador (BCI), con énfasis en los métodos para el procesamiento de datos con el fin de comprender de mejor manera la actividad cerebral por el trabajo de Jacques Vidal de la Universidad de California y en los años 90 se hicieron las primeras pruebas en humanos con metodos no invasivos [1].

Parte importante de estas investigaciones es la recopilación de datos, la cual depende del tipo de equipo a utilizar. El equipo medico y profesional tiene costos muy elevados, por lo que en la investigación se ha utilizado equipos no invasivos de baja fidelidad, pero funcionales, tal es el caso de [1], [2], [3] y [4]. Parte de usar equipo relativamente económico es hacer que los estudios sean accesibles para todos, esta accesibilidad también hace referencia a comunidades de código abierto entre las mas grandes de estas se puede mencionar OpenBCI, una empresa dedicada a proveer las herramientas necesarias para medir las señales eléctricas del cuerpo a cualquiera con una computadora. En la página de la empresa se encuentra documentación abierta tanto de software como de hardware para lograr medir las señales eléctricas del cuerpo, tal y como se muestra en [1].

Gran parte de las investigaciones en la última década se han centrado en el procesamiento de las señales y los métodos para extraer las características de estas. Al principio se pensaba que las señales EEG eran valores aleatorios, pero se han ido encontrando diferentes modelos matemáticos en el dominio del tiempo, frecuencia y tiempo-frecuencia capaces de clasificar y diferenciar patrones en las señales [5], [3].

El procesamiento de las señales en crudo es fundamental para lograr controlar robots como en el caso de [6] que controlan un robot o en el caso de [7] y [2] que controlan prótesis de mano y brazo. El fin de controlar estos dispositivos es hacer actividades riesgosas o imposibles para los usuarios e implementarlas en robots controlándolo completamente como si fuese parte del cuerpo humano.

Respecto a la Universidad del Valle de Guatemala, se ha utilizado señales EEG para otro tipo de aplicaciones. En su mayoría la lectura de estas para una neuro retroalimentación y estimular diferentes partes del cerebro. Prueba de ello son los trabajos realizados en el 2018 [8] y [9] que utilizaron todo el equipo de OpenBCI, tanto la CytonBoard como el Ultracortex para mejorar concentración y reducir estrés en atletas de alto rendimiento. En el 2019 se trabajó con la misma CytonBoard, pero con otro tipo de sensores receptores, en este caso el ElectroCap, para generar pulsos binaurales y lograr así disminuir los desordenes del sueño en los atletas de alto rendimiento [10].

[[NO ES NECESARIO USAR
Y newline. PARA DEJAR UNA LÍNEA ENTRE PÁRRAFOS. BASTA CON DAR UN
ENTER. YA CAMBIÉ VARIOS EN EL CAPÍTULO ANTERIOR Y ENTRE EL PRIMER
Y SEGUNDO PÁRRAFO DE ESTE CAPÍTULO.]]

La población mundial con algún tipo de problema motriz o degenerativo ha ido aumentando en los últimos años. Entre las enfermedades que los afectan cabe mencionar lesiones medulares, infarto cerebral, esclerosis, distrofia muscular, paraplejia y problemas del habla, entre otras. En Guatemala no es diferente el caso. No solamente afectan las enfermedades antes mencionadas, sino también existen amputaciones de miembros o extremidades por enfermedades, accidentes y por el conflicto armado interno. La mayoría de estos accidentes son de tránsito, por ejemplo, en el año 2017 se registraron 10,354 colisiones solo en la ciudad de Guatemala según el Instituto Nacional de Estadística, la causa de la mayoría es el exceso de velocidad y el uso del teléfono [11]. En cuanto a las enfermedades, gran parte de estas se da por gangrena y diabetes. Las amputaciones por el pie diabético son bastante comunes, médicos españoles aseguran que existe una probabilidad 15 veces mayor de sufrir amputación para los diabéticos en comparación con los no diabéticos [12].

Uno de los principales retos sociales en la actualidad es la atención a este segmento de personas que sufren limitaciones importantes, tienen necesidades especiales y cierto grado de dependencia. Los sistemas de salud y atención social alrededor del mundo han estado invirtiendo en hospitales, centros de rehabilitación y asistencia domiciliaria para este grupo de afectados. Todo esto con el fin de mejorar la calidad de vida de los antes mencionados, mejorar su bienestar y darles autonomía en actividades diarias como alimentación, aseo y trabajo. También facilitar su movilidad y comunicación con el mundo [7].

Por otro lado, también tenemos las actividades de riesgo para los seres humanos. Ya sea en ambientes hostiles o situaciones donde se requiera sustituir el trabajo humano por el trabajo robótico por motivos de eficiencia, costos o modernización. Así mismo en el ámbito de la robótica asistencial frecuentemente utilizada en los centros de rehabilitación antes mencionados y asistentes para cirugías, entre otros.

En consecuencia de lo anterior, ha surgido en el mundo la necesidad de investigar la posibilidad de controlar robots con movimientos que parezcan naturales basados en la actividad eléctrica del cuerpo humano. Los estudios con señales electromiográficas han mostrado un gran avance y son de las más utilizadas para los casos de prótesis. Sin embargo, presentan ciertos inconvenientes como el proceso de estudio a cada paciente en específico, por el tipo de problema que tuvo y los músculos de los que se puede obtener la señal. Así mismo, cuando el paciente presenta complicaciones para mover estos músculos o ha pasado mucho tiempo después del accidente, no se pueden captar de manera correcta las señales EMG. Tomando en cuenta también que los métodos no invasivos para obtener señales EMG provocan confusión en la captación de las señales [2]. En el caso de los asistentes robóticos o control de robots en general, se necesita que al menos una extremidad este disponible para el control del robot. Lo cual hace que se pierda una extremidad para el trabajo que se esta realizando, o en el caso de pacientes con enfermedades degenerativas ni siquiera se puedan mover estas extremidades. Es por esto que a partir de la década pasada se ha mostrado interés en el control de los dispositivos con señales EEG, las cuales no presentan los problemas anteriormente mencionados.

En la Universidad del Valle de Guatemala se cuenta con dispositivos como el robot R17, dispositivos prostéticos y dispositivos animatrónicos, pero ninguno controlado por señales EEG. Tener control con señales EEG de estos podría ayudar a cursos de carreras como ingeniería Biomédica. También se debe tomar en cuenta el interés que estos generarían en estudiantes potenciales y así continuar con las líneas de investigación de varios años del departamento, con la finalidad de entregar soluciones a la sociedad capaces de resolver problemas reales como los antes mencionados.

4.1. Objetivo general

Diseñar e implementar una interfaz cerebro-computador (BCI) que permita controlar sistemas robóticos por medio de señales electroencefalográficas (EEG).

4.2. Objetivos específicos

- Establecer un mecanismo de adquisición, filtrado y visualización en tiempo real de señales EEG.
- Seleccionar características adecuadas para el reconocimiento de patrones en señales EEG.
- Evaluar e implementar algoritmos para la clasificación de movimientos o gestos, a partir de características y patrones de señales EEG.
- Desarrollar una BCI que traduzca los resultados de la clasificación de señales en comandos para un sistema robótico.

Podemos usar Latex para escribir de forma ordenada una fórmula matemática.

Este proyecto consiste en el desarrollo de una primera fase de una BCI, donde se diseña e implementa una BCI no invasiva capaz de controlar dispositivos robóticos y animatrónicos en tiempo real a nivel de simulación. Para controlar dichos dispositivos se tomarán señales EEG de individuos realizando diferentes actividades. ****[[MEJOR: correspondientes a distintas actividades. EN LUGAR DE: imaginando mover las extremidades]]**. Estas señales se procesarán y se probarán con diferentes métodos de clasificación para obtener el menor error posible. Los métodos de clasificación anteriormente mencionados se basarán en el reconocimiento de patrones con aprendizaje automático. En base a la clasificación realizada se enviarán comandos a ejecutar por el robot o dispositivo animatrónico al que esté conectado la interfaz. Cabe mencionar que esta fase no es la final del proyecto, se espera que los resultados sirvan como base para implementar el diseño físicamente y lograr controlar el dispositivo robótico con señales EEG recibidas del cerebro humano en tiempo real.

El proyecto está dividido en tres módulos principales. El primero es el encargado de la obtención de las señales electroencefalográficas en tiempo real, para este módulo se espera observar en tiempo real la actividad cerebral. El segundo modulo es el de procesamiento y clasificación de las señales. En este módulo se procesarán las señales a manera de limpiar la señal mediante filtros para luego obtener las características de estas. Las características se utilizarán para reconocer patrones y así clasificar con aprendizaje automático. El último modulo a implementar es el desarrollo e implementación de la parte gráfica. Primero se realizará la interfaz gráfica capaz de desplegar las señales en tiempo real y las características obtenidas. Segundo, se desarrollará un simulador capaz de generar el movimiento que se espera realice el robot físico, en base a la actividad cerebral recopilada.

****[[MENCIONAR QUE, DEBIDO A LA PANDEMIA, EL ALCANCE DEL PROYECTO SE VIO LIMITADO.]]**

El desarrollo de los tres módulos anteriormente mencionados se vio afectado por la pandemia de COVID-19, a continuación, se detalla de que forma afecto la situación de la

pandemia cada módulo en específico, lo cual repercutió de manera significativa en el alcance que se tenía previsto para este proyecto de investigación. El primer modulo se vio afectado debido a que no se tuvo acceso al equipo de recepción de señales EEG que tiene la Universidad del Valle de Guatemala, por lo que fue imposible utilizar la OpenBCI y el ElectroCap para capturar las señales en tiempo real.

Respecto al segundo módulo, se tuvo inconvenientes debido a que no se contaba con señales propias. El rendimiento del clasificador dependía del tipo de datos con el que se le entrenará, por lo que al usar diferentes bases de datos se obtuvieron diferentes resultados. Mismo motivo por el cual la investigación parecía no avanzar durante varias semanas pues el clasificador no proporcionaba los resultados esperados, hasta que se opto por cambiar la base de datos y de esta manera ya se obtuvo mejores resultados.

El tercer modulo quizá fue el que menos se vio afectado de los tres, para este modulo se pensaba utilizar el robot R17 de la UVG para fines demostrativos del correcto funcionamiento del proyecto. Sin embargo, debido a la misma situación de la pandemia fue imposible acceder al modelo físico por lo que se procedió a trabajar el modelo a nivel simulación al igual que dos manipuladores seriales más para sustituir lo que al principio se esperaba que fueran el R17 y los dispositivos animatrónicos de la universidad.

[[MEJOR USAR SECCIONES NUMERADAS]]

6.1. Ondas Cerebrales

Las ondas cerebrales son la raíz de todos nuestros pensamientos, emociones y comportamientos. Son la comunicación entre las neuronas de nuestro cerebro. Se producen cuando grupos de neuronas se comunican con otros en forma de pequeños pulsos sincronizados. Las ondas cerebrales varían según la actividad que se este relacionando, se mide en microvoltios y se clasifican según su frecuencia en (Hz). Las de frecuencias bajas se asocian al sueño y cansancio, mientras que las frecuencias altas con estrés y estado alerta [13]. En el cuadro 1 se pueden apreciar las clasificaciones que comúnmente se le hacen y el nombre con el que se les conoce, aun que en la práctica no es tan sencillo diferenciarlas.

6.2. Electroencefalograma

El electroencefalograma es un estudio que monitorea la actividad electrofisiológica y registra la actividad eléctrica del cerebro. Este se relaciona con la actividad neuronal dentro del cerebro. Las señales que registra son conocidas como EEG y son fluctuaciones de voltaje que resultan de la corriente iónica entre las neuronas del cerebro en un periodo de tiempo [5].

Para captar las señales se posicionan electrodos alrededor del cerebro y se registran las diferencias de potenciales entre estos. La captación de estas señales se considera compleja, debido a que son señales estocásticas que presentan grandes variaciones dependiendo de diferentes factores como: la estructura craneal del paciente, el estado mental del mismo, niveles de concentración, movimientos musculares, movimientos involuntarios y del posicionamiento que se les dé a los electrodos [5].

Nombre de la Onda	Frecuencias (Hz)	Descripción
Delta	0.1-4	Son de baja frecuencia y altamente penetrantes. Se generan en alta meditación y etapas profundas del sueño. Tienen gran amplitud y se asocian con regeneración y sanación en el cuerpo. Su amplitud varía entre los 20 y 200 uV.
Theta	4-8	Se presenta en niños mayores a 13 años y en adultos que tienen complicaciones del sueño. También presente en desordenes hidrocefálicos y cuando hay altos niveles de estrés. Su amplitud varía entre los 20 y 100 uV.
Alfa	8-14	Aparece en los lados del cerebro, con una mayor amplitud en el lado dominante. Aparece al cerrar los ojos y relajarse, desaparece al abrirlos. Después de los 30 años aparece frecuentemente en la mayoría de personas. Su amplitud varía entre los 20 y 60 uV.
Beta	14-30	Aparece de manera simétrica en ambos lados del cerebro. Se acentúa con el consumo de drogas sedantes o hipnóticas. Se presenta comúnmente en pacientes con ansiedad. Su amplitud varía entre los 2 y 20 uV.
Gamma	>30	Esta frecuencia se pudo medir hasta que se implementó la tecnología digital, analógicamente era imposible. Esta frecuencia aparece en periodos de hiper alerta y altas percepciones de los sentidos.

Cuadro 1: Clasificación Ondas Cerebrales, [13] y [5].

6.3. Sistema de posicionamiento 10-20

El sistema internacional de posicionamiento es un estándar internacional definido por la Federación Internacional de Sociedades de Electroencefalografía (FISE) en 1958. Describe la ubicación del cráneo donde deben colocarse los electrodos para medir señales EEG. El estándar se estableció en base a la relación entre la localización del electrodo y el área de la corteza cerebral ubicada bajo el, los números 10 y 20 hacen referencia a que la distancia entre los electrodos vecinos puede ser 10 o 20 % de la distancia total entre la zona frontal y posterior, o de derecha a izquierda del cráneo, cada zona tiene asignada una letra para identificar el lóbulo y un numero para identificar en que hemisferio se encuentra, si el numero es par pertenece al hemisferio derecho y si es impar al hemisferio izquierdo. Cada lóbulo del cerebro se puede identificar con una letra correspondiente. Para los lóbulos frontal, temporal, central, parietal y occipital sus identificadores son F, T, C, P, O respectivamente [5].

Por lo regular se utilizan cuatro referencias anatómicas para posicionar los electrodos. La primera es el nasión, este es el punto entre el hueso frontal y los dos huesos de la nariz del cráneo. El segundo es el inion, este se encuentra en el punto inferior trasero del cráneo y es la proyección mas prominente del hueso occipital. Por ultimo los puntos preauriculares detrás de los oídos [5]. En la Figura 1 se puede apreciar gráficamente la ubicación de los electrodos para un sistema 10-20. El estándar 10-20 es para una cantidad pequeña de electrodos, normalmente 21. Con la necesidad de más ondas y más canales se han establecido nuevos estándares como el 10-10 y 10-5 para 81 y 256 canales, respectivamente.




Figura 1: Ubicación electrodos según estándar 10-20 extendido [5].

6.4. Interfaz Cerebro Computador

La interfaz cerebro computador (BCI) por sus siglas en inglés Brain Computer Interface es capaz de medir la actividad cerebral y traducirlas para poder procesarlas con una computadora. El objetivo principal de estas es monitorear y estudiar la actividad cerebral ante diferentes escenarios. El estudio de la actividad cerebral se logra mediante las señales EEG y la calidad de estas depende del equipo de medición a utilizar. La diferencia en el tipo de señales a obtener depende de los equipos a utilizar. Existe una gran variedad de dispositivos para captar las señales, por un lado, están los dispositivos clínicos y médicos que entregan mejor calidad de señales, pero su costo es bastante elevado. Por otro lado, tenemos los equipos portátiles utilizados comúnmente para proyectos de investigación y desarrollo, pero nunca podrán sustituir a los dispositivos médicos [5].

Un sistema BCI esta conformado por varias etapas tal y como se observa en la Figura 2. La primera de ellas sería la adquisición de señales EEG en crudo, esto se puede realizar en tiempo real o guardar para un análisis posterior. La siguiente etapa sería el preprocesamiento donde se aplican filtros por lo regular para separar frecuencias y eliminar ruido o frecuencias no deseadas como la de la corriente eléctrica (60 Hz). Luego está la extracción de características lo cual se considera el procesamiento en sí, estas características se obtienen mediante métodos matemáticos como la transformada rápida de Fourier (FFT), transformada de ondículas (Wavelets), transformada de Hilbert-Huang, número de cruces por cero (*Zero Crossing ZC*) o el promedio del valor absoluto (*Mean Absolute Value MAV*). Siguiendo a esto, tenemos la etapa de clasificación e interpretación de las características obtenidas mediante aprendizaje automático. Por último, tenemos la señal de salida al actuador o efector, dependiendo de la clasificación realizada anteriormente [5].

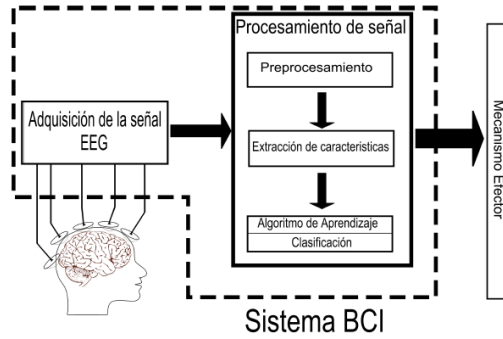


Figura 2: Proceso para BCI convencionales [3]

6.4.1. Tipos de BCI

Invasivo: Necesitan de neurocirugías para poder instalarlos en la materia gris. La señal es de muy buena calidad, pero con el tiempo la señal se va degradando porque el cuerpo lo rechaza y forma cicatrices [5].

Parcialmente invasivo: Se implantan dentro del cráneo, pero no en la materia gris mediante cirugías. Su calidad se considera intermedia, pero no se degradan con el paso del tiempo porque el cuerpo no los rechaza [5].

No invasivo: La mayoría de los trabajos de investigación y desarrollo en los últimos años se realizan con esta tecnología. Son sencillos de instalar, remover y no requieren cirugías. Sin embargo, la calidad de las señales no es tan buena como las mencionadas anteriormente y no se pueden detectar señales de alta frecuencia [5].

6.5. Aprendizaje automático

El aprendizaje automático, comúnmente conocido como *Machine Learning* es el estudio científico de algoritmos y modelos estadísticos que las computadoras utilizan para tomar decisiones sin ser programadas explícitamente. Según el doctor Adeel Najmi es cuando las maquinas pueden crear o refinar autónomamente modelos de decisión [14]. Esta nace como una subdisciplina de la Inteligencia Artificial (IA) que construye modelos matemáticos basado en los datos que se le proporcionan, conocidos como datos de entrenamiento para posteriormente realizar toma de decisiones o predicciones. Entre las aplicaciones principales se encuentran: reconocimiento de imágenes, sonido y texto, diagnósticos médicos, predicción de eventos, minería de datos, robótica, finanzas, telecomunicaciones y biomédica [14].

El proceso de machine learning se podría dividir en dos procesos. El primer proceso de decisión y ejecución. El segundo proceso de aprendizaje por medio de la retroalimentación. Ambas trabajan de la mano para lograr la mejora continua y poder tomar las mejores decisiones o predicciones sin haberlo programado explícitamente [14]. Existen diferentes tipos de algoritmos de aprendizaje automático que se utilizan como clasificadores, a continuación se detallan dos de ellos.

6.5.1. Máquina de Soporte Vectorial

Una Máquina de Soporte Vectorial conocida con el acrónimo SVM por sus siglas en inglés (*Support Vector Machine*) es un algoritmo de aprendizaje automático supervisado que suele emplearse con fines de clasificación y regresión binaria tal y como se observa en la Figura 3. En la actualidad se implementa el algoritmo para resolver problemas de regresión, agrupamiento y multclasificación. Por su alto rendimiento se ha implementado en visión artificial, reconocimiento de patrones y análisis de series temporales [10].




Figura 3: Representación datos de entrada en dos dimensiones y transformados [15].

El algoritmo construye un modelo a partir de ejemplos de entrenamiento ya clasificados, capaz de predecir a que categoría pertenecerá un nuevo ejemplo. El funcionamiento del SVM se basa en encontrar la mejor línea recta, plano o hiperplano según la dimensión del problema que divida el conjunto de datos en dos clases, lo cual consigue aplicando los siguientes conceptos [15], los cuales se observan en la Figura 4.

- **Hiperplano:** Plano que separa y clasifica linealmente un conjunto de datos.
- **Vectores de apoyo:** Son los puntos críticos de datos más cercanos a la línea del hiperplano y que al eliminarse alterarían la posición del este.
- **Margen:** Distancia entre el hiperplano y el dato más cercano de cualquiera de los conjuntos.
- **Dimensión VC:** Cuyo nombre se deriva de quienes contribuyeron con grandes aportes para los SVM (Vapnik-Chervonekis). VC es el conjunto de funciones disponibles y la dimensión es la cantidad máxima de puntos que se pueden separar de todas las formas posibles mediante el conjunto VC. A mayor dimensión, menor error del conjunto de entrenamiento y mayor confianza.
- **Kernel:** También conocido como núcleo es el conjunto de funciones matemáticas utilizadas para transformar los datos de entrada en la forma deseada. Conectan la linealidad y no linealidad de las SVM, cuando los datos parecen no tener forma de separarlos.

6.5.2. Redes Neuronales Artificiales

Conocidas por el acrónimo RNA, el nombre proviene de sus similitudes en organización, comportamiento y estructura con su homólogo biológico. Por ser un tipo de aprendizaje




Figura 4: Hiperplano para datos en tres dimensiones [15].

automático supervisado, esta herramienta aprende y se forma a sí misma tratando de minimizar la función de pérdida que evalúa a la red en su totalidad mediante propagación hacia atrás. Tratando de emular el sistema neuronal biológico, las neuronas artificiales se organizan en capas y las capas en una estructura jerárquica similar a la del cerebro[3], tal y como se aprecia en la Figura 5.




Figura 5: Proceso de RNA [3]

Las redes neuronales artificiales emulan los siguientes conceptos clave:

- **Procesamiento Paralelo:** Debido a la gran cantidad de neuronas que intervienen en un proceso, es posible efectuar procesos en paralelo.
- **Memoria Distribuida:** La información esta distribuida por la sinapsis de la red, existiendo redundancia en caso falle o se dañe alguna sinapsis.
- **Adaptabilidad al entorno:** Es posible conceptualizar a partir de casos previos y aprender en base a la experiencia proporcionada por la información de las sinapsis.

Los conceptos claves en los que se basa la red neuronal artificial hace que sea ampliamente utilizada para implementar clasificadores con aprendizaje automático [3].

6.6. Extracción de características

La extracción de características es un proceso por el cual se busca reducir la dimensionalidad de un largo numero de datos a grupos más pequeños cuyo procesamiento sea más sencillo, logrando expresar sus características más significativas con una menor cantidad de datos [16]. Para señales bioelectricas se utilizan diversos tipos de características, a continuación una breve explicación de las utilizadas en esta investigación.

6.6.1. Valor Absoluto Promedio

El valor absoluto promedio conocido comunmente como MAV por el acronimo de sus siglas en ingles *Mean Absolute Value* es el promedio del valor absoluto de la amplitud de la señal [17] y se define como:

$$\text{MAV} = \frac{1}{N} \sum_{n=1}^N |x_n| \quad (1)$$

6.6.2. Número de Cruces por Cero

El número de cruces por cero conocido como ZC por sus siglas en inglés *Zero Crossing* es tal y como su nombre lo indica la cantidad de veces que la amplitud de una señal cruza el 0 del eje X. En señales bioelectricas se acostumbra a usar un umbral para evitar que se cuenten cruces de valores menores a dicho umbral los cuales por lor egular representan ruido [17]. El ZC se utiliza como estimador de las propiedades en el dominio de la frecuencia y se define como:

$$\text{ZC} = \sum_{n=1}^{N-1} [\text{sgn}(x_n \times x_{n+1}) \cap |x_n - x_{n+1}| \geq \text{Umbral}]; \quad (2)$$
$$\text{sgn}(x) = \begin{cases} 1 & \text{si } x \geq \text{Umbral} \\ 0 & \text{si Diferente} \end{cases}$$

6.6.3. Curtosis

La curtosis es también conocida como el cuarto momento de una distribución, esta medida esta relacionada con los extremos o "colas" de la distribución. La curtosis indica la cercanía entre los datos y los valores de tendencia central, una curtosis de 3 indica que la distribución es normal [18]. Se calcula con la siguiente expresión:

$$k = \frac{\frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})^4}{\left(\frac{1}{N} \sum_{n=1}^N (x_n - \bar{x})^2 \right)^2} \quad (3)$$

6.6.4. Varianza

La varianza indica que tan cerca o lejos están los datos de la media, lo hace calculando el promedio de las diferencias al cuadrado entre los datos y su media, razón por la cual es muy sensible a datos atípicos [19].

$$V = \frac{1}{N-1} \sum_{n=1}^N |x_n - \bar{x}|^2 \quad (4)$$

6.6.5. Potencia Media

La potencia media de una señal es la suma de las muestras absolutas al cuadrado en el dominio del tiempo dividido entre el largo de la señal, equivalente al cuadrado de su nivel RMS [20].

$$P = \frac{1}{N} \sum_{n=1}^N |x_n|^2 \quad (5)$$

6.6.6. Distancia Máxima Mínima

La distancia maxima-minima es comunmente conocida como MMD por sus siglas en ingles *Maximum Minimum Distance* y se basa en la formula de distancia derivada del teorema de Pitagoras para encontrar la distancia entre el punto maximo y el minimo de una ventana determinada [21], se define como:

$$\text{MMD} = \sum_{n=1}^N | \sqrt{\Delta x_n^2 + \Delta y_n^2} | \quad (6)$$

6.6.7. Ondículas

Conocidas como *Wavelets*, es una herramienta poderosa en el procesamiento de señales debido a la capacidad de realizar análisis tanto en el tiempo como en la frecuencia de fenómenos estacionarios y no estacionarios. Este principio se basa en la aproximación de señales usando la superposición de señales. La energía de estas ondas se encuentra concentrada en el tiempo y sirve como herramienta para el análisis de fenómenos transientes, no estacionarios y variantes en el tiempo [22].

**[[AGREGAR DESCRIPCIONES, ECUACIONES, ETC. DE LAS CARACTERÍSTICAS COMUNES QUE SE USAN PARA ANALIZAR/CLASIFICAR SEÑALES EEG.]]

6.7. Manipulador Serial

Los manipuladores seriales estan formados por una serie de eslabones rigidos y juntas. Cada junta tiene un grado de libertad que puede ser traslacional en el caso que se trate de una junta prismatica o rotacional si es una junta revoluta tal y como se observa en la Figura 6. El movimiento de las juntas cambia la pose relativa de los eslabones. Por lo regular un extremo del manipulador serial se encuentra aterrizado y se conoce como bancada, el otro extremo que se encuentra libre se conoce como efector final [23].




Figura 6: Tipos de juntas, q_1 revoluta y q_2 prismática [23]

Una manera sistematica de describir la geometria de un manipulador serial es con la notación de Denvit-Hartenberg. Los parametros de Denavit-Hartenberg un eslabon define la relacion espacial enter dos juntas vecinas. El eslabon se describe con cuatro parametros los cuales son:

- θ_j angulo entre ejes X.
- d_j el largo del eslabon en el eje Z.
- a_j el largo del eslabon en el eje X.
- α_j el angulo entre ejes Z.

Siempre se deben respetar las dos restricciones siguientes: x_j intersecta a z_{j-1} y x_j es perpendicular a z_{j-1} [23].

**[[DH: TAL VEZ NO TANTO DETALLE, AUNQUE SÍ MENCIONAR CONCEPTOS BÁSICOS DE SISTEMAS ROBÓTICOS]]

[[Procesamiento, filtros, frecuencia: ENFATIZAR EN EL PROCESAMIENTO QUE TÍPICAMENTE SE HACE PARA LAS SEÑALES EEG]].

6.8. Procesamiento de Señales

Una señal es una descripción formal de un fenómeno evolucionando en el tiempo o espacio. El procesamiento de señales hace referencia a cualquier operación manual o mecánica que modifique, analice o manipule la información contenida en la señal. El procesamiento de señales se puede hacer de manera analógica o digital, cada una presenta sus ventajas y desventajas. En la actualidad se ha hecho énfasis en el procesamiento digital de señales por su inherente universalidad para diversos tipos de aplicaciones [24].

El procesamiento digital de señales tiene el inconveniente que no se pueden representar las señales como funciones continuas. Esto debido a que las computadoras y máquinas de medición no captan datos todo el tiempo, su funcionamiento está regido por algún reloj o tiempo establecido y la información que almacenan se encuentra en arreglos finitos de memoria. Por lo que se discretizan las señales, lo cual consiste en una secuencia de números ordenados [24], tal y como se observa en la Figura 7.




Figura 7: Señal continua y discreta [24]

Para llevar a cabo el procesamiento digital de señales es necesario filtrar la señal analógica, convertir la señal analógica a digital con un ADC, procesarla, convertir la señal digital en analógica con un DAC y filtrar de nuevo la señal analógica [25]. Dicho proceso se puede apreciar en el diagrama de la Figura 8.




Figura 8: Diagrama de bloques Procesamiento Digital de Señales [25]

7.1. Características en el Dominio del tiempo

Después de haber extraído la información de los 64 canales de la base de datos, se procedió a seleccionar solamente los canales de interés para el trabajo. Los cuales son C3, C1, Cz, C2 y C4 según la Figura 1. Luego de extraer los datos de estos cinco canales, se procedió a extraer las características. Al inicio se extrajeron solamente el número de cruce por ceros (ZC) y el valor absoluto promedio (MAV). Sin embargo, como se puede observar en las Figuras 9 y 10 al aplicar SVM y RNA respectivamente, ninguno presenta resultados aceptables. Importante mencionar que para todos los resultados con SVM presentados a continuación se utilizó el 90 % de las muestras para entrenar y el 10 % para evaluar, de las 45 muestras obtenidas. Los resultados obtenidos con RNA se obtuvieron utilizando un tamaño de capa oculta de 10, la función de entrenamiento SCG debido al balance de consumo de memoria y calidad de resultados que presenta. Se utilizó un 80 % de las muestras para entrenar, 10 % para validar y 10 % para probar. En cuanto a las etiquetas utilizadas 1 y 2 se refieren a abrir y cerrar el puño izquierdo y derecho, respectivamente. Para SVM se tuvo que cambiar el 2 por el 0 para poder obtener de manera automática la matriz de confusión.

Debido a que los resultados de los clasificadores no eran los esperados, se procedió a calcular 2 características más las cuales son varianza y curtosis. Con estas dos características se obtuvieron mejores resultados para ambos clasificadores, los cuales se pueden observar en las Figuras 11 y 12 para SVM y RNA, respectivamente.

En busca de mejorar el rendimiento de los clasificadores, se procedió a utilizar las cuatro características a la vez. Sin embargo, los resultados obtenidos son muy similares a los obtenidos solamente con varianza y curtosis. Los resultados se pueden apreciar en las Figuras 13 y 14.




Figura 9: Matriz de confusión para SVM con kernel de función de base radial con características ZC y MAV.

Como se puede observar los resultados aun no son los deseados, a pesar que para el caso de SVM se eligió el núcleo que mejor resultado presentó siendo RBF para ZC, MAV y polinomio grado 3 para varianza, curtosis y las cuatro características juntas. Los resultados fueron mejorando, sin embargo, se procederá a probar con características en el dominio de la frecuencia cómo Transformada Rápida de Fourier o Wavelets, las cuales se espera den mejores resultados.

7.2. Características en el Dominio de tiempo frecuencia

Por instucciones del asesor se implemento el clasificador en el dominio de la frecuencia, aplicando Wavelets a las misma base de datos en lugar de características en el dominio del tiempo.

Se inicio trabajando con los canales C3, C1, C6, Cp5, T9, T10, Poz y Po4. Luego separar los canales por sus bandas de frecuencia con el uso de Wavelets para observar su dispersión en el tiempo se procedió a utilizar la aplicación de *Classification Learner* de *MATLAB* para observar que tipo de clasificador presentaba mejor rendimiento. Se realizaron pruebas para los primeros 2 canales, los primeros 4 canales y los 8 canales mencionados anteriormente obteniendo el mejor rendimiento para cada prueba con los metodos de K-vecinos cercanos, SVM kernel cubico y discriminante lineal, tal y como se observa en las figuras 15, 16, 19, respectivamente.

Como se puede observar en las figuras 15, 16, 19 los resultados del clasificador no son los esperados, independientemente del clasificador porque al utilizar redes neuronales tampoco se logro el rendimiento deseado tal y como se muestra en las figuras 20 y 21. Los motivos por los cuales pudo no funcionar fue que con 2 canales existían muy pocos datos para clasificar correctamente. Al utilizar 4 y 8 canales se tuvo el problema que al concatenar las

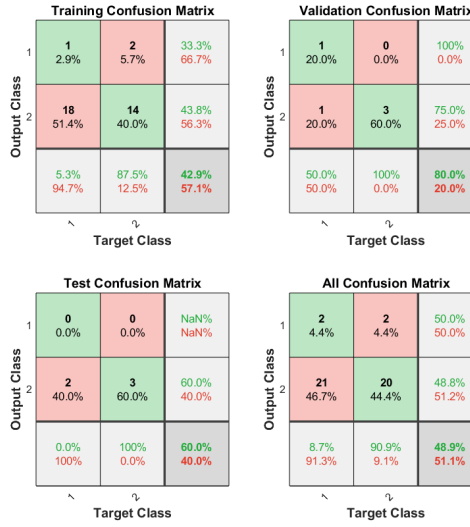


Figura 10: Matriz de confusión para RNA con características ZC y MAV.

características de todos los canales juntas el número de características era mayor al número de muestras, un problema conocido en aprendizaje automático como sobrecarga de datos.

Con estos resultados se observó que el clasificador SVM grado 3 presentaba siempre los mejores resultados o por lo menos estaba entre los primeros 3 al utilizar la aplicación de *MATLAB* por lo que se decidió utilizar solamente ese clasificador para las siguientes pruebas. Acompañado de redes neuronales como se había hecho desde un principio.

Por lo que se procedió a implementar un clasificador binario que en lugar de decidir entre 3 clases como las pruebas anteriores, solo tuviera que separar en 2 clases con 2 canales esperando obtener mejores resultados.

Se probaron las diferentes combinaciones de clases y los mejores resultados se obtuvieron al clasificar las clases 0 y 1, cuya matriz de confusión se muestra en la figura 22. Como se puede observar los resultados aún no son los esperados, el clasificador en todas las pruebas muestra estar sesgado hacia la clase 0 esto se puede deber a que el número de muestras es el doble en comparación a las otras clases.

Se finalizaron las pruebas y no se obtuvo el resultado esperado por parte de los clasificadores, por lo que se optó por utilizar diferentes canales, en esta ocasión el O1 y el P3. Se obtuvieron los resultados que se muestran en las figuras 23 y 24, para SVM y redes neuronales, respectivamente.

Luego de extraer características por medio de wavelets y aplicar los clasificadores de SVM kernel cúbico y Redes Neuronales, aún no se obtienen los resultados esperados. Por lo que se opta, por elegir diferentes canales, siendo estos el Pz y el Fpz. Los resultados se pueden observar en las figuras 25 y 26, para SVM y redes neuronales, respectivamente.

Al finalizar estas pruebas se puede ver que los clasificadores no presentan buen rendimiento, esto se puede deber a los pocos datos con los que se cuenta en la base de datos. Por




Figura 11: Matriz de confusión para SVM con kernel de polinomio grado tres con características varianza y curtosis.

lo que se buscara otra base de datos para validar el funcionamiento de los clasificadores.

7.3. Base de datos de sueño

Debido a los malos resultados obtenidos con la base de datos anterior, se procedió a buscar otra base de datos con la cual se pudieran validar los clasificadores. Se eligió la base de datos de sueño de Physionet, debido a que tiene gran cantidad de señales EEG y están correctamente identificadas según sus clases, por lo que el tamaño de las señales no sería una limitante para el rendimiento de los clasificadores.

7.3.1. Varianza

Se inició analizando la base de datos en el dominio del tiempo las características que se extrajeron fueron 5, las cuales son: Valor absoluto promedio, número de cruces por cero, varianza, potencia media y curtosis. Para las 4 señales proporcionadas cuyos nombres son fpz, pz, eog y emg. Se extrajeron épocas equivalentes a 30 segundos, tomando en cuenta que las grabaciones fueron hechas a una frecuencia de 100 Hz. Luego de extraer las características se procedió a implementar los clasificadores, los resultados que se obtuvieron se muestran en las figuras 27 y 28, para SVM y redes neuronales, respectivamente.

7.3.2. Distancia máxima mínima

A pesar de obtener buenos resultados, se buscó mejorar utilizando otro tipo de características en el dominio del tiempo. Se utilizó la mayoría de características anteriores, a




Figura 12: Matriz de confusión para RNA con características varianza y curtosis.

diferencia que se sustituyo la varianza por la entropía de la señal y se obtuvieron los siguientes resultados que se muestran en las figuras 29 y 30 , para SVM y redes neuronales, respectivamente.

7.3.3. Wavelets

Por último, se probo clasificar las señales con característica en el dominio tiempo-frecuencia aplicando wavelets, en lugar de las 5 características extraídas anteriormente en el dominio del tiempo. Cuyos resultados se pueden observar en las figuras 31 y 32 , para SVM y redes neuronales, respectivamente.

Luego de analizar los resultados de todas las pruebas, se procede a elegir Maquinas de Soporte Vectorial de la segunda prueba. Utilizando la entropía de la señal, pues presenta de los mejores resultados de clasificación a pesar de ser en el dominio del tiempo, lo cual se puede considerar como una ventaja por su fácil implementación en señales en tiempo real y bajo coste computacional.

Confusion Matrix				
Output Class	0	1		
	2 40.0%	0 0.0%	100% 0.0%	
	0 0.0%	3 60.0%	100% 0.0%	
		0	1	
		100% 0.0%	100% 0.0%	100% 0.0%
		Target Class		

Figura 13: Matriz de confusión para SVM con kernel de polinomio grado tres con las cuatro características.

Training Confusion Matrix

Output Class	1	5 14.3%	1 2.9%	83.3% 16.7%
	2	13 37.1%	16 45.7%	55.2% 44.8%
		27.8% 72.2%	94.1% 5.9%	60.0% 40.0%
		Target Class		

Validation Confusion Matrix

Output Class	1	2 40.0%	1 20.0%	66.7% 33.3%
	2	0 0.0%	2 40.0%	100% 0.0%
		100% 0.0%	66.7% 33.3%	80.0% 20.0%
		Target Class		

Test Confusion Matrix

Output Class	1	0 0.0%	1 20.0%	0.0% 100%
	2	3 60.0%	1 20.0%	25.0% 75.0%
		0.0% 100%	50.0% 50.0%	20.0% 80.0%
		Target Class		

All Confusion Matrix

Output Class	1	7 15.6%	3 6.7%	70.0% 30.0%
	2	16 35.6%	19 42.2%	54.3% 45.7%
		30.4% 69.6%	86.4% 13.6%	57.8% 42.2%
		Target Class		

Figura 14: Matriz de confusión para RNA con las cuatro características.




Figura 15: Matriz de confusión para KNN con wavelets 2 canales.




Figura 16: Matriz de confusión para SVM grado 3 con wavelets 4 canales.




Figura 17: Matriz de confusión para discriminante lineal con wavelets 8 canales.




Figura 18: Matriz de confusión para RN con wavelets 2 canales.



Figura 19: Matriz de confusión para discriminante lineal con wavelets.




Figura 20: Matriz de confusión para RN con wavelets 2 canales.

Matriz de confusión RN

0		139	5	21		100.0%
1		75	2	11	85.2%	14.8%
2		64		13		100.0%
3						
		27.0%				
		73.0%	100.0%	100.0%		
	0	1	2	3		
	Predicted Class					

Figura 21: Matriz de confusión para RN con wavelets 8 canales.

Matriz de confusión SVM grado 3

0	149	16	90.3%	9.7%
1	70	18	20.5%	79.5%
	68.0%	52.9%		
	32.0%	47.1%		
	0	1		
	Predicted Class			

Figura 22: Matriz de confusión para SVM grado 3 con wavelets para clases 0 y 1.

Matriz de confusión SVM grado 3

0	147	3	15	89.1%	10.9%
1	65	10	13	11.4%	88.6%
2	74	2	1	1.3%	98.7%
	51.4%	66.7%	3.4%		
	48.6%	33.3%	96.6%		
	0	1	2		
	Predicted Class				

Figura 23: Matriz de confusión para SVM grado 3 con wavelets para canales O1 y P3.

Matriz de confusión RN					
True Class	0	112	24	29	100.0%
	1	62	9	17	70.5%
	2	59	7	11	9.1%
	3				
		26.6%	17.5%		
		73.4%	82.5%	100.0%	
		0	1	2	3
		Predicted Class			

Figura 24: Matriz de confusión para RN con wavelets para canales O1 y P3.

Matriz de confusión SVM grado 3					
True Class	0	86	5	74	52.1%
	1	51	14	23	15.9%
	2	49	4	24	31.2%
	3				
		46.2%	60.9%	19.8%	
		53.8%	39.1%	80.2%	
		0	1	2	
		Predicted Class			

Figura 25: Matriz de confusión para SVM grado 3 con wavelets para canales Pz y Fpz.

Matriz de confusión RN					
True Class	0	91	13	61	100.0%
	1	57	13	18	64.8%
	2	42	11	24	14.3%
	3				
		30.0%	29.7%		
		70.0%	70.3%	100.0%	
		0	1	2	3
		Predicted Class			

Figura 26: Matriz de confusión para RN con wavelets para canales Pz y Fpz.

Matriz de confusión RN									
True Class	1	2					90.3%	9.7%	
	2	5	6			6	35.3%	64.7%	
	3		6	65		4	86.7%	13.3%	
	4	1		9	56		84.8%	15.2%	
	5					37	100.0%		
		82.4%	40.0%	87.8%	100.0%	78.7%			
		17.6%	60.0%	12.2%		21.3%			
		1	2	3	4	5			
		Predicted Class							

Figura 30: Matriz de confusión para RN con MMD.

Matriz de confusión SVM grado 3									
True Class	0	336	2	1	32	1	90.3%	9.7%	
	1	4	736	90	32	38	81.8%	18.2%	
	2	2	95	693		2	87.5%	12.5%	
	3	39	32		112	21	54.9%	45.1%	
	4	1	6		16	421	94.8%	5.2%	
		88.0%	84.5%	88.4%	58.3%	87.2%			
		12.0%	15.5%	11.6%	41.7%	12.8%			
	0	1	2	3	4				
		Predicted Class							

Figura 31: Matriz de confusión para SVM grado 3 con wavelets.

Matriz de confusión RN								
True Class	1	327		2	43		87.9%	12.1%
	2	4	682	124	32	58	75.8%	24.2%
	3	3	81	706	2		89.1%	10.9%
	4	59	32		89	24	43.6%	56.4%
	5	5	7	3	15	414	93.2%	6.8%
		82.2%	85.0%	84.6%	49.2%	83.5%		
		17.8%	15.0%	15.4%	50.8%	16.5%		
	1	2	3	4	5			
Predicted Class								

Figura 32: Matriz de confusión para RN con wavelets.


8.1. Robot

Esta sección se implementó para validar el correcto funcionamiento del clasificador automático antes mencionado. Tomando en cuenta que al inicio del proyecto se planifico comprobar el funcionamiento del mismo con el robot R17 del laboratorio de la universidad, pero por motivos fuera de nuestro alcance debido a la pandemia del COVID-19 no fue posible tener acceso a dicho robot, por lo que se procedió a implementar el modelo del mismo robot a nivel simulación para validar el funcionamiento del clasificador como si se tuviese acceso al modelo real de la universidad. Adicionalmente al modelo del R17, también se implemento la simulación de dos manipuladores seriales más para verificar el funcionamiento del clasificador sin importar el robot que debia controlar, estos manipuladores seriales son el UR5 y el Puma 560, dichos modelos y su implementación se detallan en las siguientes secciones. Importante mencionar que la animación de los tres modelos se hizo con la librería de Robótica de Peter Corke [23]. Por lo que se propone desarrollar los diferentes modelos de robots en MATLAB y validar el correcto funcionamiento de la BCI a nivel simulación, con el fin de sustituir esta parte de simulación, por el robot de los laboratorios para proximas fases del proyecto.


8.1.1. R17

Como se menciona anteriormente, se utilizo el manipulador R17 porque es el modelo que posee el Departamento de Ingeniería Electrónica, Mecatrónica y Biomédica de la UVG, el cual se muestra en la Figura 33a. El R17 es un manipulador serial de ST Robotics. Este tiene cinco grados de libertad más carrera, tal y como se observa en la Figura 33b tiene 1 junta prismática y 5 revolutas. Debido a que este modelo no lo incluye la toolbox de Peter

Corke se tuvo que crear el mismo.



(a) Modelo Experimental



(b) Juntas

Figura 33: Manipulador Serial R17 de 5 GDL (más carrera) [26].

Como primer paso se establecieron los parámetros de Denavit-Hartenberg del R17, los cuales se muestran en el Cuadro 2, una vez ya definidos dichos parámetros se define el número de juntas, el tipo de junta `Prismatic()` o `Revolute()` y los parámetros para cada junta. Luego de tener establecidas las juntas se procede a definir el robot como un objeto `SerialLink()` y por último se establece la transformada de base para ajustar el modelo a las coordenadas globales utilizando `transl()` y `trotx()`.

θ_j	d_j	a_j	α_j
0	q_1	0	$-\pi/2$
$q_2 + \pi/2$	-0.355	0	$-\pi/2$
$q_3 + \pi/2$	0	0.375	0
q_4	0	0.375	0
$q_5 - \pi/2$	0	0	$-\pi/2$
$q_6 + \pi/2$	0	0	0

Cuadro 2: Parámetros de Denavit-Hartenberg para manipulador R17 de 5 GDL (más carrera).

Luego de definir el objeto serial se procedió a utilizar el comando `teach()` para definir cuales serían las poses para cada comando. Las poses generadas según cada clase se presentan en el Cuadro 3. Cada pose representa un movimiento angular en el plano XY del robot, siendo 0° , 180° , 45° , 135° y 90° para las clases 1 a la 5, respectivamente. Dichas poses se logran con las configuraciones de las juntas presentadas en el Cuadro 3. En la Figura 34 se observan las poses para las configuraciones mostradas en el Cuadro 3. La primera configuración denominada Clase 0 es la pose que tiene el robot cuando no se detecta actividad. Para que el robot alcance la pose deseada sin exceder los límites de las juntas y realizando una trayectoria suave se utilizó la función `jtraj()` con un intervalo de tiempo de $1/4$ de segundo para llegar a la trayectoria y el mismo tiempo para retornar a la configuración inicial. Por lo que efectuar cada trayectoria completa le tomaría medio segundo al manipulador real, variable que es modificable según la aplicación del manipulador.

Junta/Clase	0	1	2	3	4	5
J1	0	0	0	0.473	0.473	0.473
J2	0	$\pi/2$	$-\pi/2$	$\pi/2$	$-\pi/2$	0
J2	0	$\pi/4$	$\pi/4$	$\pi/4$	$\pi/4$	$\pi/4$
J4	0	$\pi/4$	$\pi/4$	$\pi/4$	$\pi/4$	$\pi/4$
J5	0	0	0	0	0	0
J6	0	0	0	0	0	0

Cuadro 3: Configuración de juntas R17 para cada clase.

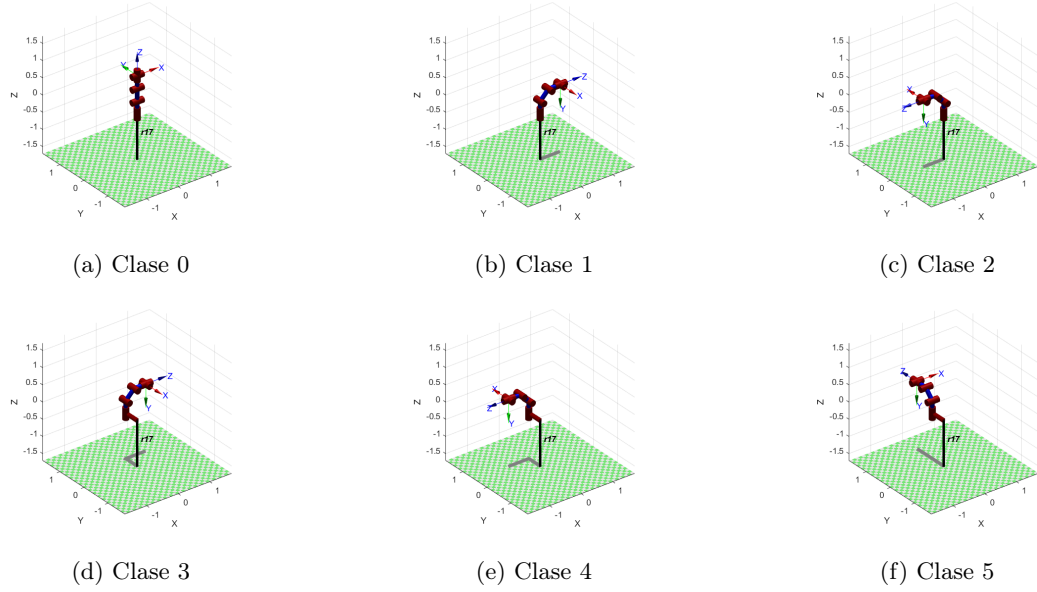


Figura 34: Configuración de juntas según clase para R17.

8.1.2. UR5

Los siguientes dos modelos de manipuladores seriales, no hubo necesidad de crear el objeto serial como en el caso del R17, porque la librería de Peter Corke ya tenía definidos los diferentes modelos. El UR5 es un manipulador serial de Universal Robots con 6 juntas revolutas tal y como se observa en la Figura 35. Se utilizó este modelo por ser un manipulador serial popular en la industria debido a su versatilidad y la cantidad de accesorios disponibles para diversas aplicaciones. Para importar el modelo ya existente se utilizó el comando `mdl_ur5`. Luego, se procedió a establecer las configuraciones de las juntas deseadas para cada clase, las cuales se presentan en el Cuadro 4 y se pueden observar en la Figura 35.




Figura 35: Juntas manipulador serial UR5 [27].

Junta/Clase	0	1	2	3	4	5
J1	0	0	0	$\pi/4$	$-\pi/4$	$\pi/2$
J2	$-\pi/2$	$-\pi$	0	$-\pi$	0	$-\pi$
J2	0	0	0	0	0	0
J4	0	0	0	0	0	0
J5	0	0	0	0	0	0
J6	0	0	0	0	0	0

Cuadro 4: Configuración de juntas UR5 para cada clase.

8.1.3. Puma 560

El último manipulador serial seleccionado es el Puma 560 de Unimation. Se eligió este modelo por ser uno de los pioneros en la robótica y por el modelo renderizado que se puede utilizar en MATLAB para animaciones gracias a la librería ARTE para MATLAB de la Universidad Miguel Hernández [28]. Este manipulador serial cuenta con 6 juntas revolutas, por lo que luego de importar el modelo del robot se procedió a utilizar el comando `teach()` para definir las configuraciones deseadas para las juntas. En el Cuadro 5 se pueden apreciar las configuraciones de las juntas para cada pose deseada según el comando entregado por el clasificador. En la Figura 35 se puede apreciar la pose del robot para cada una de las configuraciones antes mencionadas.

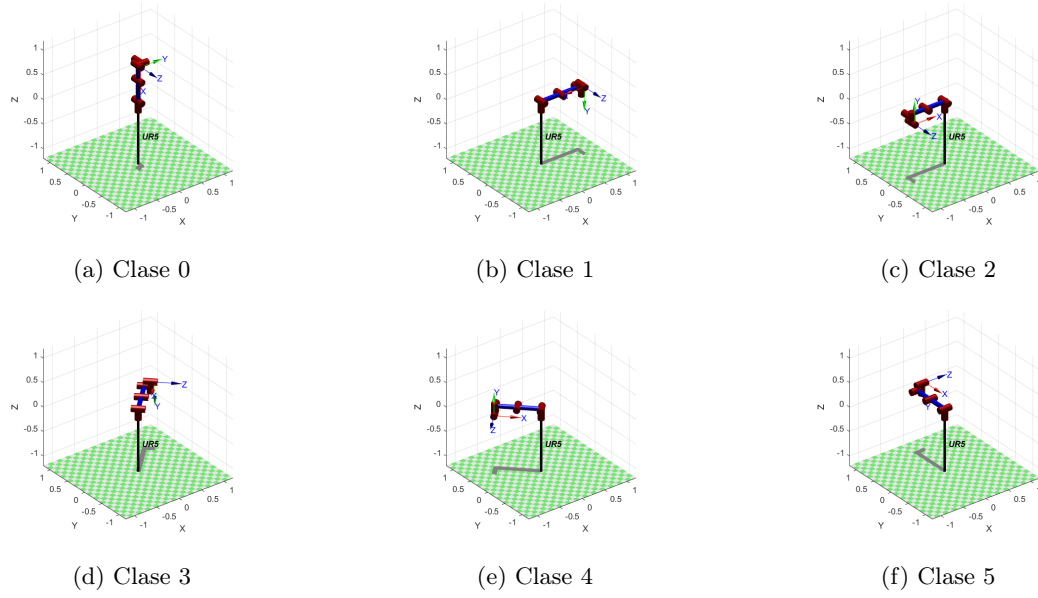


Figura 36: Configuración de juntas según clase para UR5.




Figura 37: Juntas manipulador serial Puma 560 [29].

Junta/Clase	0	1	2	3	4	5
J1	0	0	0	$\pi/4$	$3\pi/4$	$\pi/2$
J2	$\pi/2$	0	π	0	0	0
J2	$-\pi/2$	$-\pi/2$	$-\pi/2$	$-\pi/2$	$-\pi/2$	$-\pi/2$
J4	0	0	0	0	0	0
J5	0	0	0	0	0	0
J6	0	0	0	0	0	0

Cuadro 5: Configuración de juntas Puma 560 para cada clase.

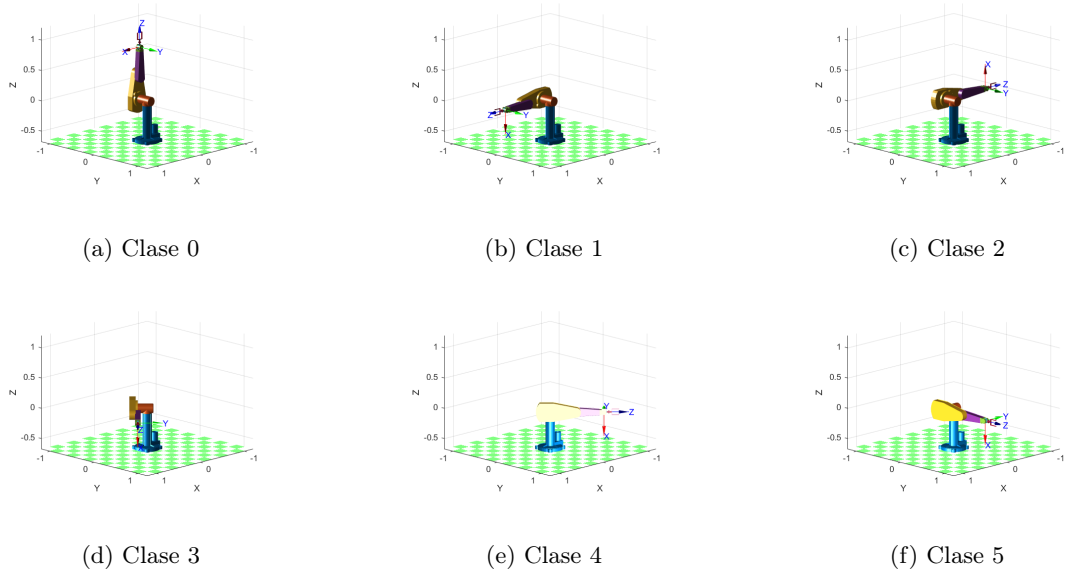


Figura 38: Configuración de juntas según clase para Puma 560.

8.2. Interfaz gráfica

Para presentar los resultados obtenidos se diseñó una interfaz gráfica que facilitara la visualización de los resultados y permitiera la interacción del usuario con la BCI de manera amigable. El desarrollo de la interfaz gráfica se llevó a cabo con el *App Designer* de MATLAB. Se consideró importante que la interfaz a diseñar fuera intuitiva y fácil de usar para el usuario sin importar los conocimientos en robótica o programación que este tenga. Para facilitar la interacción del usuario con la interfaz se ordenó la información a desplegar en dos pestañas las cuales son "Control Manual" y "Control Automático". Adicional a estas dos pestañas, se tiene un panel al lado izquierdo que siempre está presente, donde se encuentra el botón para iniciar o detener la grabación de datos para el modo automático, dicho botón también sirve para seleccionar el tipo de control que manipulará al robot.

8.2.1. Control Manual

Al inicializar la interfaz, se desplegará la pestaña de control manual, tal y como se muestra en la Figura 39. La idea de esta pestaña es permitir al usuario familiarizarse con los movimientos que es capaz de realizar el robot dependiendo del comando que seleccione. El botón de iniciar grabación se encuentra en off, lo cual indica que el modo de control automático no está activo y se puede controlar el robot de manera manual. En la parte superior de la pestaña aparece un cuadro de lista desplegable donde el usuario puede seleccionar el modelo del robot que desea controlar entre las tres opciones disponibles, las cuales son: R17, UR5 y Puma 560. Inmediatamente al seleccionar el robot, se desplegará en la parte central de la pestaña la imagen del robot que se seleccionó las cuales se pueden observar en las Figuras 33, 35 y 37 para el R17, UR5 y Puma 560, respectivamente. Adicional a las imágenes también

se despliega una figura de MATLAB cuyas opciones varían según la opción seleccionada y se presentaron en la sección anterior en las Figuras 34, 36 y 38 donde se visualizarán los movimientos que ejecute el robot acorde al comando seleccionado por el usuario en tiempo real. Estos comandos aparecen en la parte inferior de la pestaña, al lado izquierdo se pueden observar los cinco botoens para los diferentes tipos de comandos y al lado derecho una breve descripción de lo que ejecutará el robot al presionar el boton correspondiente.

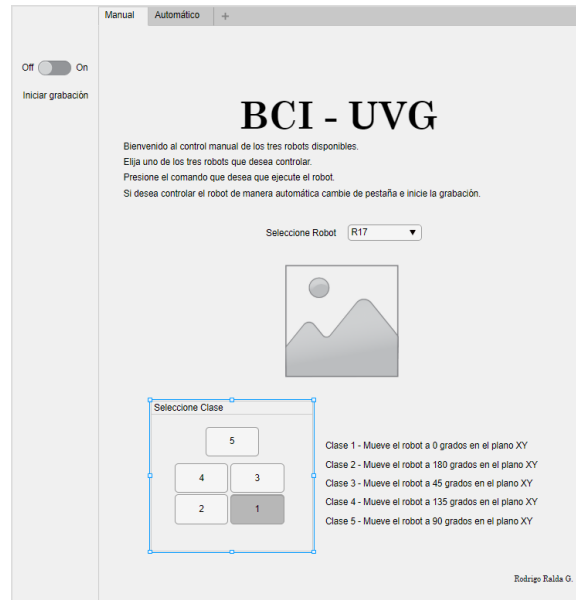


Figura 39: Pestaña modo manual.

8.2.2. Control Automático

La segunda pestaña de la interfaz es para visualizar y activar todo lo relacionado al control automático de la interfaz. El modo automático permacera apagado hasta que se presione el botón de iniciar grabación en el panel izquierdo de la itnerfaz. Antes de presionar dicho boton se recomienda al usuario familiarizarse con los datos que desplegará la nueva pestaña. En la parte superior izquierda se puede observar un deslizador el cual se recomienda configurar antes de iniciar la grabación, en este deslizador se puede seleccionar un valor entre 1 y 30 segundos. El significado de este tiempo es cuantos segundos se desea que dure la ventana para capturar datos y clasificar para luego enviar el comando al robot, por lo que el tiempo seleccionado se vera reflejado en el eje horizontal de cada uno de los cuatro gráficos de la parte central de la pestaña y tambien en el tiempo entre la ejecución de los comandos del robot seleccionado. En la parte superior derecha se puede observar el resultado del clasificador, la etiqueta de "Clase actual" despliega el resultado del clasificador y este resultado se actualiza a cada intervalo de tiempo según lo sleccionado en el deslizador. En el centro de la pestaña automático se pueden observar 4 gráficas, las cuales corresponden a las cuatro señales que se estan recopilando en tiempo real para clasificarlas cada cierto tiempo definido por el deslizador antes mencionado. Las dos señales superiores corresponden a los canales EEG de Fpz y Pz, las dos señales inferiores corresponden a los canales de electrooculografía (EOG) y electromiografía (EMG), de izquierda a derecha respectivamente. En la parte inferior de esta pestaña se despliega una pestaña donde el usuario puede leer una breve descripción de lo que

esta viendo, también puede cambiar a la pestaña "Desplegar Características" donde observara las 16 características utilizadas para llevar a cabo la clasificación. Estas características se actualizan según el tiempo determinado en el deslizador.

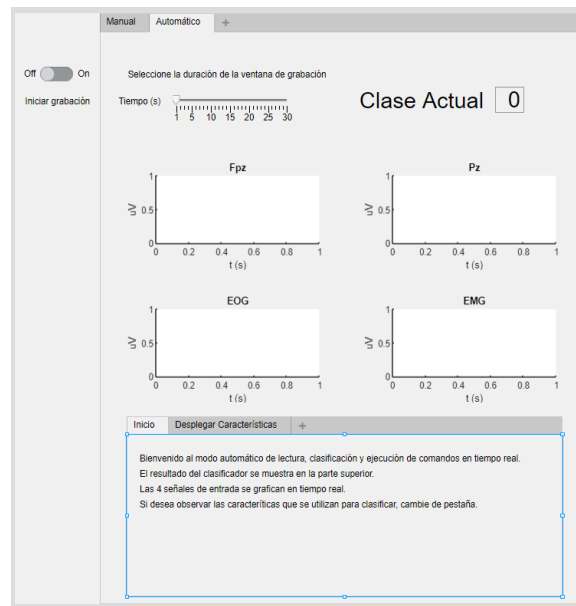


Figura 40: Pestaña modo automático.

CAPÍTULO 9

Conclusiones

CAPÍTULO 10

Recomendaciones

- [1] P. Schembri, R. Anthony y M. Pelc, “Detection of Electroencephalography Artefacts using Low Fidelity Equipment”, ene. de 2017, págs. 65-75. DOI: 10.5220/0006398500650075.
- [2] K. Correa Arana y A. Vivas Alban, “Protesis de mano virtual movida por señales encefalográficas EEG”, es, *Prospectiva*, vol. 14, págs. 99-110, dic. de 2016, ISSN: 1692-8261. dirección: http://www.scielo.org.co/scielo.php?script=sci_arttext&pid=S1692-82612016000200099&nrm=iso.
- [3] R. Sepúlveda, M. Oscar, G. Díaz, D. Gutierrez y O. Castillo, “Clasificación de señales encefalográficas mediante redes neuronales artificiales”, Español, *Computación y Sistemas*, 2015, ISSN: 1405-5546. dirección: <https://www.redalyc.org/articulo.oa?id=61536854006>.
- [4] J. Esqueda Elizondo, L. Hernández-Manzo y M. Pinto-Ramos, “Manipulación de un brazo robótico mediante señales electroencefalográficas”, *Revista de Tecnología e Innovación*, vol. 3, págs. 89-98, jun. de 2016.
- [5] L. J. Gómez Figueroa, “Análisis de señales EEG para detección de eventos oculares, musculares y cognitivos”, págs. 1-14, 2016.
- [6] S. Brewster, *Un robot dirigido con la mente ayuda con telepresencia a personas discapacitadas*, Visitado por última vez 04 de abril de 2020., 2015. dirección: <https://www.technologyreview.es/s/5373/un-robot-dirigido-con-la-mente-ayuda-con-telepresencia-personas-discapacitadas>.
- [7] R. Ceres, M. A. Mañanas y J. M. Azorín, “Interfaces y Sistemas en Rehabilitación y Compensación Funcional para la Autonomía Personal y la Terapia Clínica”, *Revista Iberoamericana de Automática e Informática industrial*, vol. 8, n.º 2, págs. 5-15, 2011, ISSN: 1697-7920. DOI: 10.1016/S1697-7912(11)70021-8. dirección: <https://polipapers.upv.es/index.php/RIAI/article/view/8576>.
- [8] J. Aguirre, “Diseño, Análisis, y Desarrollo de un Sistema de Entrenamiento para Mejorar el Desempeño de los Atletas del Comité Olímpico Guatemalteco”, 2018.

- [9] M. Godoy, “Diseño e implementación de módulo de recopilación de señales y módulo de retroalimentación”, 2018.
- [10] J. P. Muñoz, “Diseño de un sistema inteligente de monitoreo de ondas EEG y generador de pulsos binaurales para combatir desórdenes de sueño en los atletas”, págs. 1-54, 2019.
- [11] D. L. Hora, *La probabilidad de sufrir una amputación de pie es 15 veces mayor en un diabético, según experto*, Visitado por última vez 04 de abril de 2020., 2018. dirección: <https://www.elpais.cr/2018/07/28/los-retos-de-vivir-con-una-protesis-en-guatemala/>.
- [12] P. Pernas, *Los retos de vivir con una prótesis en Guatemala*, Visitado por última vez 04 de abril de 2020., 2019. dirección: <https://lahora.gt/la-probabilidad-de-sufrir-una-amputacion-de-pie-es-15-veces-mayor-en-un-diabetico-segun-experto/>.
- [13] Brainworks, *WHAT ARE BRAINWAVES?*, Visitado por última vez 04 de abril de 2020. dirección: <https://brainworksneurotherapy.com/what-are-brainwaves>.
- [14] A. Najmi, *WHAT IS MACHINE LEARNING?*, Visitado por última vez 04 de abril de 2020., 2017. dirección: <https://supplychainbeyond.com/what-is-machine-learning/>.
- [15] Numerentur, *Máquina de Soporte Vectorial SVM*, Visitado por última vez 03 de junio de 2020., 2018. dirección: <http://numerentur.org/svm/>.
- [16] S. Khalid, T. Khalil y S. Nasreen, “A survey of feature selection and feature extraction techniques in machine learning”, *Proceedings of 2014 Science and Information Conference, SAI 2014*, págs. 372-378, oct. de 2014. DOI: 10.1109/SAI.2014.6918213.
- [17] A. Phinyomark, S. Hirunviriya, C. Limsakul y P. Phukpattaranont, “Evaluation of EMG Feature Extraction for Hand Movement Recognition Based on Euclidean Distance and Standard Deviation”, vol. 2010, mayo de 2010, págs. 856-860.
- [18] MATHWORKS, *Kurtosis*, Visitado por última vez 11 de septiembre de 2020., 2020. dirección: <https://es.mathworks.com/help/stats/kurtosis.html>.
- [19] —, *Variance*, Visitado por última vez 12 de septiembre de 2020., 2020. dirección: <https://es.mathworks.com/help/matlab/ref/var.html#bundkwe-1>.
- [20] —, *Measure the Power of a Signal*, Visitado por última vez 11 de septiembre de 2020., 2020. dirección: <https://es.mathworks.com/help/signal/ug/measure-the-power-of-a-signal.html?lang=en>.
- [21] K. Aboalayon, M. Faezipour, W. Almuhammadi y S. Moslehpour, “Sleep Stage Classification Using EEG Signal Analysis: A Comprehensive Survey and New Investigation”, *Entropy*, vol. 18, n.º 9, pág. 272, ago. de 2016, ISSN: 1099-4300. DOI: 10.3390/e18090272. dirección: <http://dx.doi.org/10.3390/e18090272>.
- [22] R. González, *Algoritmo basado en Wavelets aplicado a la detección de incendios forestales*. Visitado por última vez 12 de septiembre de 2020., 2010. dirección: http://catarina.udlap.mx/u_dl_a/tales/documentos/mel/gonzalez_g_ra/capitulo3.pdf.
- [23] P. I. Corke, *Robotics, Vision & Control: Fundamental Algorithms in MATLAB*, Second. Springer, 2017, ISBN 978-3-319-54412-0.

- [24] P. P. y M. Vetterli, *Signal Processing for Communications*, EPFL Press. [Online], 2008. dirección: <https://doi.org/10.1201/9781439808009>.
- [25] e. a. M. Martínez L. Gómez, *Introducción al Procesado Digital de Señales*, Universidad de Valencia. [Online], 2009. dirección: <http://ocw.uv.es/ingenieria-y-arquitectura/1-1/tema1.pdf>.
- [26] *R17 Robot Manual*, ST Robotics, Cambridge, Reino Unido, 2017.
- [27] A. Topalidou-Kyniazopoulou, “Motion Planning Strategy For a 6-DOFs Robotic Arm In a Controlled Environment”, M.S. thesis, Dept. Computer Science. Ger., Bonn Univ., Bonn, Alemania, 2017. dirección: https://www.ais.uni-bonn.de/theses/Angeliki_Topalidou-Kyniazopoulou_Master_Thesis_07_2017.pdf.
- [28] A. Gil, *ARTE A Robotic Toolbox for Education in MATLAB*. Elche, España: Universidad Miguel Hernández, 2014. dirección: http://arvc.umh.es/arte/index_en.html.
- [29] *USING THE PUMA 560 ROBOT*, Jerry Rutherford, 2012. dirección: <http://rutherford-robotics.com/PUMA/%USING%5C%20THE%5C%20PUMA%5C%20ROBOT.pdf>.

CAPÍTULO 12

Anexos

12.1. Planos de construcción

CAPÍTULO 13

Glosario

fórmula Una expresión matemática. 8

latex Es un lenguaje de marcado adecuado especialmente para la creación de documentos científicos. 8